



Universidad Internacional de La Rioja
Facultad de Ciencias de la Salud

Máster Universitario en Bioinformática

Atlas de expresión interactivo de papaya
(Carica papaya)

Trabajo fin de Estudio presentado por:	Alejandro Pascual Hernández
Tipo de trabajo:	Tipo 3
Director/a científico:	Noé Fernández Pozo
Director/a académico:	Carolina Sánchez Rodríguez
Fecha:	15/07/2026

Resumen

La papaya (*Carica papaya*) es una planta herbácea semileñosa nativa de regiones tropicales y subtropicales, donde se ha establecido como un recurso fundamental para la agricultura. La Food and Agriculture Organization (FAO) la clasifica como la tercera fruta tropical en relevancia comercialmente, con una producción media de 28.998 toneladas por hectárea y una producción global que excede los 14 millones de toneladas en 2022. Pese a su importancia global, la información genómica disponible se encuentra fragmentada y dispersa. El presente estudio presenta un atlas de expresión desarrollado a partir del minado de datos de repositorios públicos, con el propósito de solventar este problema. Un total de 8 datasets con datos de RNA-Seq, disponibles en el European Nucleotide Archive (ENA), fueron seleccionados y procesados para este estudio. El pipeline bioinformático utilizado para este proceso incluyó un control de calidad, un alineamiento, cuantificación y normalización de los datos incluidos en los sets de datos. Dichos sets corresponden con estudios que abordan aspectos críticos de la fisiología de la planta, como la respuesta a estreses bióticos y abióticos, dimorfismo sexual, maduración del fruto, morfogénesis del gineceo, entre otros. Los resultados finales fueron integrados en la base de datos IHSM Subtropicals dentro de la herramienta del atlas de expresión (https://ihsmstropicals.uma.es/easy_gdb/index.php). Este portal genómico está basado en EasyGDB. Con todo esto se pretende transformar la información bruta y dispersa en información centralizada y de acceso libre, y con ello ayudar a investigadores y entidades agrícolas a acelerar los planes de mejora genética y profundizar en el entendimiento de la biología molecular de la papaya.

Palabras clave: Papaya, Atlas de expresión, EasyGDB

Abstract

Papaya (*Carica papaya* L.) is a semi-woody herbaceous plant native to tropical and subtropical regions, where it has been established as a fundamental agricultural resource. The Food and Agriculture Organization (FAO) classifies it as the third most commercially significant tropical fruit, with an average yield of 28.998 tons per hectare and a global production exceeding 14 million tons in 2022. Despite its global significance, the genomic information available is fragmented and lacks centralization. The present study proposes a gene expression atlas, developed through data mining of public repositories, with the aim of addressing this gap. A total of eight RNA-seq datasets, available in the European Nucleotide Archive (ENA), were selected and processed for this study. The bioinformatics pipeline included quality control, alignment, quantification and normalization of data included in the sets. Each dataset corresponds to a study addressing critical aspects of plant physiology, such as responses to biotic and abiotic stresses, sexual dimorphism, fruit ripening, and gynoecium morphogenesis, among others. The final outcome of this research was integrated into the gene expression atlas tool of IHSM Subtropicales (https://ihsmstropicales.uma.es/easy_gdb/index.php), a genomic portal based on EasyGDB. Through this we expect to transform raw, dispersed data into centralized, open-access biological information, thereby enabling researchers and agricultural entities to accelerate genetic breeding programs and deepen the understanding of papaya molecular biology.

Keywords: Papaya, Expression atlas, EasyGDB

Índice de contenidos

Índice de acrónimos:	10
1. Introducción	11
1.1. Características e importancia del <i>Carica papaya</i>	11
1.1.1. Importancia económica	11
1.1.2. Importancia nutricional	11
1.1.3. Importancia médica	12
1.2. Recursos genómicos y aplicaciones biotecnológicas	12
1.2.1. Genoma de la papaya	12
1.2.2. Determinación sexual	12
1.2.3. El Papaya Ringspot Virus (PRSV) y las variedades Rainbow/SunUp	13
1.3. RNA-Seq y análisis bioinformático	14
1.3.1. El RNA-Seq	14
1.3.2. El Pipeline	15
1.3.3. Herramientas principales	16
1.4. Portales genómicos y atlas de expresión	17
1.5. IHSM Subtropicals	18
1.5.1. Otros ejemplos de atlas de expresión	19
1.6. Justificación del estudio	20
2. Objetivos	21
2.1. Objetivo general	21
2.2. Objetivos específicos	21
3. Materiales y métodos	22
3.1. Recursos computacionales	22
3.2. Obtención de los datos de RNA-Seq	23

3.3.	Obtención del genoma de referencia.....	25
3.4.	Pipeline bioinformático	25
3.4.1.	Creación de un entorno de trabajo	27
3.4.2.	Control de calidad.....	27
3.4.3.	Descontaminación de las lecturas	28
3.4.4.	Procesado de las lecturas	29
3.4.5.	Alineamiento de las lecturas	30
3.4.6.	Conteo de las lecturas	30
3.4.7.	Normalización de los datos	31
3.4.8.	Formateo de nombre y cambio de orden	31
3.5.	Creación del atlas de expresión.....	31
3.6.	Creación de archivos de anotaciones.....	32
4.	Resultados	34
4.1.	Unificación, centralización y estandarización de los datos.....	34
4.1.1.	Datos iniciales.....	34
4.1.2.	Lecturas contaminadas.....	38
4.1.3.	Lecturas procesadas	39
4.1.4.	Lecturas alineadas a la referencia	43
4.1.5.	Atlas de expresión de <i>Carica papaya</i>	44
4.2.	Evaluación de patrones de expresión diferencial entre tipos sexuales en papaya utilizando el atlas de expresión.	45
4.3.	Archivos de anotaciones.....	53
5.	Discusión	55
6.	Conclusiones.....	61
	Referencias bibliográficas.....	62

Anexo A.	Scripts	68
Anexo B.	Material complementario	99

Índice de figuras

Figura 1. Representación simplificada del proceso de RNA-seq	15
(Elaborada con BioRender.com)	15
Figura 2. Previsualización base de EasyGDB.....	19
Figura 4. Gráfica “Per Base Sequence Quality Plot” de la calidad de las lecturas sin procesar del BioProject PRJNA565901 obtenida con MultiQC	36
Figura 5. Gráfica “Per Base Sequence Content” de la calidad de las lecturas sin procesar del BioProject PRJNA470602 obtenida con MultiQC	36
Figura 6. Gráfica “Adapter Content” de la calidad de las lecturas sin procesar del BioProject PRJNA713527 obtenida con MultiQC	37
Figura 7. Gráfica “Sequence Duplication Levels” de la calidad de las lecturas sin procesar del BioProject PRJNA549650 obtenida con MultiQC	37
Figura 9. Gráficas “Per Sequence GC content” de la calidad de las lecturas sin procesar de los BioProject PRJNA880626 (arriba) y PRJNA591254 (abajo) obtenidas con MultiQC	39
Figura 10. Gráfica “Per Base Sequence Quality Plot” de la calidad de las lecturas procesadas del BioProject PRJNA565901 obtenida con MultiQC	40
Figura 11. Gráfica “Per Base Sequence Content” de la calidad de las lecturas procesadas del BioProject PRJNA470602 obtenida con MultiQC	40
Figura 12. Gráfica “Adapter Content” de la calidad de las lecturas procesadas del BioProject PRJNA713527 obtenida con MultiQC.....	41
Figura 13. Gráfica “Sequence Length Distribution” de la calidad de las lecturas procesadas del BioProject PRJNA565901 obtenida con MultiQC	41
Figura 15. Gráficas “Per Sequence GC Content” de la calidad de las lecturas descontaminadas y procesadas del BioProject PRJNA880626 (arriba); y solamente procesadas de los BioProject PRJNA470602 (abajo) obtenidas con MultiQC	43
Figura 16. Página de bienvenida de la base de datos local	45
Figura 17. Gráficas generadas con distintos métodos de reducción de la dimensionalidad ...	47

Figura 18. Representación gráfica de la expresión diferencial de diferentes genes con una mayor expresión en la flor femenina	49
Figura 19. Representación gráfica de la expresión diferencial de diferentes genes con una mayor expresión en la flor masculina	50
Figura 20. Representación mediante cartas de expresión del gen AGL11 en distintas muestras	51
Figura 21. Mapa de calor de la expresión diferencial de diferentes genes de interés en distintos estadios de desarrollo de la flor y en distintos tipos sexuales	52
Figura 22. Gráfico de réplicas de la expresión del gen CYCD3-1, en las distintas condiciones experimentales	52
Figura 23. Tabla descargable de los valores medios de expresión de los genes de interés, en distintos estadios de desarrollo de la flor y distintos tipos sexuales	53
Figura 24. Ejemplo reducido de archivo de anotaciones	54

Índice de tablas

Tabla 1. Tabla resumen con la información de los distintos datasets tratados	23
Tabla 2. Niveles de calidad medidos en QPHRED y su relación con la probabilidad de error de la base	24
Tabla 3. Visualización de tabla de metadatos para un dataset en concreto	25
Tabla 4. Conjunto de datos obtenidos	35
Tabla 5. Tabla de porcentaje de lecturas alineadas del BioProject PRJNA470602	44
Tabla 6. Tabla con los genes candidatos. Información de los genes extraída de la base de datos de SwissProt y del estudio	48

Índice de acrónimos:

- **BAM:** *Binary Alignment Map*
- **cDNA:** *Complementary DNA* (ADN complementario)
- **CSIC:** Consejo Superior de Investigaciones Científicas
- **EBI:** *European Bioinformatics Institute*
- **EEZ:** Estación Experimental del Zaidín
- **ENA:** *European Nucleotide Archive*
- **FAO:** *Food and Agriculture Organization* (Organización de las Naciones Unidas para la Alimentación y la Agricultura)
- **GFF / GTF:** *General Feature Format / Gene Transfer Format*
- **ICA:** *Independent Component Analysis* (Análisis de Componentes Independientes)
- **IHSM:** Instituto de Hortofruticultura Subtropical y Mediterránea "La Mayora"
- **MDS:** *Multidimensional Scaling* (Escalamiento Multidimensional)
- **mRNA:** *Messenger RNA* (ARN mensajero)
- **NCBI:** *National Center for Biotechnology Information*
- **NGS:** *Next-Generation Sequencing* (Secuenciación de Nueva Generación)
- **PCA:** *Principal Component Analysis* (Análisis de Componentes Principales)
- **PRSV:** *Papaya Ringspot Virus* (Virus de la mancha anular de la papaya)
- **RPKM / FPKM:** *Reads/Fragments Per Kilobase of transcript per Million mapped reads*
- **SRA:** *Sequence Read Archive*
- **SSH:** *Secure Shell*
- **TPM:** *Transcripts Per Million*
- **t-SNE:** *t-Distributed Stochastic Neighbor Embedding*
- **UMA:** Universidad de Málaga
- **UMAP:** *Uniform Manifold Approximation and Projection*

1. Introducción

En este primer capítulo se aborda el contexto general y la relevancia de la especie *Carica papaya*, destacando su importancia a nivel económico, nutricional y médico. Asimismo, se describen los recursos disponibles en la actualidad y se introduce el análisis bioinformático mediante RNA-Seq. Finalmente, se establece el marco teórico y la justificación de este trabajo.

1.1. Características e importancia del *Carica papaya*

La papaya (*Carica papaya*) es una planta semileñosa, comúnmente de un solo tallo, que se distribuye ampliamente por las regiones tropicales y subtropicales, presenta un hábito de crecimiento perenne de corta duración. Los hábitos de crecimiento de la papaya se caracterizan por sus grandes hojas palmeadas, desarrollo rápido, tallo, peciolo y fruto hueco, y una gran plasticidad fenotípica (1).

Se trata de una planta trioica, la cual puede presentar plantas femeninas, masculinas y hermafroditas (1–3), aunque, para el cultivo comercial, las plantas femeninas y hermafroditas son las mayormente utilizadas (4).

1.1.1. Importancia económica

La FAO cataloga la papaya como el tercer cultivo tropical más importante con un rendimiento promedio de 28,998 toneladas por hectárea. La producción global excedió los 14 millones de toneladas en 2022, siendo México, India, Brasil y Malasia algunos de los países con mayor porcentaje de producción (5).

1.1.2. Importancia nutricional

La papaya es una fruta conocida por su bajo coste y gran valor nutricional gracias a su contenido en fitonutrientes tanto en hojas y frutos inmaduros y maduros (2,6). Sobre otras frutas la papaya presenta gran cantidad de tiamina, folato, riboflavina, niacina, vitaminas A, B1, B2 y C, y fibra (7). Presenta bajo contenido en grasas y proteínas, por lo que el índice calórico es bajo también. Los principales azúcares presentes incluyen la glucosa, sacarosa, y fructosa. También se ha comprobado la presencia de un gran número de elementos esenciales, como pueden ser potasio, sodio, fósforo, calcio, hierro, zinc, cobre, manganeso, y magnesio.

1.1.3. Importancia médica

Las propiedades farmacéuticas son tan amplias que en algunos estudios se considera casi un fármaco a la vez que un alimento (7). Es por esta razón que es tan ampliamente consumida (8) y ha sido uno de los remedios tradicionales frente a diferentes enfermedades. Presenta un alto contenido en agentes inmunoestimulantes y antioxidantes (9,10). Ayuda a la cicatrización de heridas así como la cura de quemaduras y es especialmente interesante en aquellas úlceras crónicas que no cicatrizan (11). También se ha comprobado que la papaína con urea tiene un efecto positivo en el desbridamiento (eliminación de tejido muerto o infectado) enzimático (12). Otros estudios sugieren muchas otras aplicaciones médicas muy interesantes para distintas afecciones y tratamientos (13,14).

1.2. Recursos genómicos y aplicaciones biotecnológicas

1.2.1. Genoma de la papaya

La papaya es una especie diploide, con un genoma de un tamaño relativamente pequeño (371 Mpb) compuesto por nueve pares de cromosomas ($2n=18$). En comparación, otros cultivos como el banano, el ciruelo, el aguacate tienen un genoma más del doble de extenso (~ 870 Mpb) (15). La variedad “SunUp” es la elegida comúnmente para la secuenciación y como genoma de referencia. Su variedad predecesora (“Sunset”) pasó por 25 generaciones de inbreeding para su obtención, como resultado de esto, muestra niveles muy bajos de heterocigosis residual (16). Esta última característica se ha destacado a la hora de proponer a la papaya como planta modelo especies arbóreas.

1.2.2. Determinación sexual

Las plantas de papaya presentan tres formas sexuales distintas femenina, masculina y hermafrodita. Estas formas sexuales están controladas mediante un sistema cromosómico X-Y. Esto se explica porque la papaya puede presentar dioecia (con plantas masculinas y femeninas) o gynodioecia (con plantas hermafroditas y femeninas).

Varios estudios sugieren que el cromosoma Y contiene una pequeña región específica que controla la expresión de las formas masculina (Y) y hermafrodita (Y^h). La forma femenina presenta cromosomas XX. Todas las combinaciones que presentan dos cromosomas Y y/o Y^h son letales; a su vez, los tipos masculino y hermafrodita son heterocigotos (XY y XY^h respectivamente) (17,18).

1.2.3. El Papaya Ringspot Virus (PRSV) y las variedades Rainbow/SunUp

El PRSV, un potyvirus, causa pérdidas generalizadas en todos los cultivos de papaya en el mundo (19,20). Las pérdidas provocadas por este virus son las mayores cuando las medimos comparándolas con otros agentes patógenos, llegando a pérdidas de hasta el 100% del cultivo. A esto se le añade el hecho de que no existen resistencias naturales identificadas en papaya en todo el mundo. Los síntomas más típicos son las hojas en mosaico, anillos verdes oscuro en frutos, y hojas enrolladas en forma de cordón (21). Se transmite a partir de áfidos y mediante transmisión mecánica (21).

Como respuesta para el control de la enfermedad provocada por este virus, se decidió generar líneas R₀ 55-1 de papaya resistentes al PRSV mediante un enfoque de “resistencia mediada por sobreexpresión de la proteína de cubierta (cp)”. Para ello se usó biobalística sobre el cultivar “Sunset” con vectores que contenían la cp de PRSV HA 5-1 (22,23). Con esto se obtuvo la variedad transgénica “SunUp”. Como ejemplo de este avance en el control de la enfermedad podemos destacar el desarrollo de la variedad híbrida transgénica “Rainbow”, la cual permitió salvar la industria de la papaya en Hawaii (22). A partir de este avance, la mayoría de las variedades cultivadas por todo el mundo pertenecen a esta variedad “SunUp” o a variedades derivadas de este, como puede ser la “Rainbow”. Yue et al., (24) realizaron estudios posteriores en el que se ensamblaron genomas tanto de la variedad predecesora “Sunset” como la variedad transgénica “SunUp”, para una posterior comparación en la que se pudo comprobar la existencia de un inserto de 1,6 Mb correspondiente a las inserciones realizadas en la transformación con biobalística.

El PRSV y, sobre todo, la investigación en la búsqueda de variedades resistentes como Rainbow y SunUp deja en evidencia lo importante que es disponer de recursos transcriptómicos unificados e integrados disponibles de forma libre. Estos recursos son necesarios para la investigación de posibles genes relacionados a la resistencia o susceptibilidad a enfermedades.

1.3. RNA-Seq y análisis bioinformático

1.3.1. El RNA-Seq

En los últimos años, el estudio de la expresión génica ha avanzado gracias a nuevas herramientas diseñadas para comprender los mecanismos moleculares que regulan el desarrollo, el crecimiento y la respuesta de los organismos a estímulos.

En este sentido, el RNA-Seq ha supuesto una auténtica revolución, ya que proporciona una visión global y muy detallada de la expresión génica mediante la secuenciación masiva del RNA mensajero (mRNA).

Esta técnica se lleva a cabo a través de la siguiente serie de pasos (**Figura 1**):

1. **Extracción total del RNA:** se realiza una extracción de RNA de la muestra de interés. Por consenso, como mínimo ha de contarse con 3 réplicas biológicas. El RNA es una molécula de muy fácil degradado por lo que este paso es muy delicado.
2. **Creación de una librería de cDNA:** el RNA original no se puede secuenciar directamente, por este motivo se crea una librería de DNA complementario (cDNA). Aunque existen varios protocolos, el método estandarizado incluye:
 - **Enriquecimiento del mRNA:** se aísla el mRNA capturándolo con secuencias *oligo-dT*, las cuales se unen específicamente a las colas *poli-A* de los mensajeros.
 - **Síntesis de la primera hebra:** utilizando cebadores aleatorios se forma la primera cadena de cDNA.
 - **Síntesis de la segunda hebra:** se sintetiza la hebra complementaria incorporando nucleótidos *dUTP*.
3. **Secuenciación masiva:** el cDNA obtenido se secuencia utilizando tecnologías NGS (Next-Generation Sequencing), siendo Illumina una de las plataformas más utilizadas. Durante este proceso, los fragmentos se secuencian de forma masiva, generando millones de “lecturas cortas” (*short reads*).
4. **Alineamiento genómico:** el último paso consiste en el alineamiento computacional con un genoma de referencia. Esto permite asignar cada lectura a una localización genómica específica y cuantificar su expresión.




Figura 1. Representación simplificada del proceso de RNA-seq

(Elaborada con BioRender.com)

Esta técnica, el RNA-Seq, tiene una serie de ventajas clave sobre otras técnicas tradicionales como la hibridación por microarrays. Tiene una mayor capacidad para detectar y cuantificar de manera precisa y sensible la expresión génica. También permite detectar tanto genes conocidos como sus isoformas, transcritos no codificantes y splicings alternativos. Todo esto hace del RNA-Seq una técnica con una amplia gama de aplicaciones en la investigación de plantas frutícolas, así como en cualquier organismo en general. Permite a los investigadores identificar y cuantificar los genes expresados en diferentes tejidos, etapas del desarrollo del fruto, condiciones de estrés y condiciones frente a patógenos. Permite, por tanto, estudiar la dinámica de la expresión génica a lo largo del tiempo frente a diferentes estímulos específicos.

En el análisis de RNA-Seq, la bioinformática es parte fundamental y central. Permite extraer la información génica y comprender los mecanismos subyacentes en diferentes condiciones biológicas.

1.3.2. El Pipeline

El análisis consta de varias etapas. En la primera de ellas se lleva a cabo el procesamiento de los datos brutos. Se aplica un control de calidad de las lecturas secuenciadas, con una posterior eliminación de adaptadores, lecturas de baja calidad y secuencias contaminantes. Con esto se garantiza la calidad de los datos que posteriormente se usará en las siguientes etapas. La siguiente de estas es el ensamblaje de las lecturas que, en el caso de papaya, se hace utilizando un genoma de referencia, más concretamente el genoma de la variedad

“Sunup”. Las lecturas se alinean sobre este genoma y se les asigna una ubicación dentro de este con lo que se puede reconstruir los transcritos expresados. En casos donde el organismo cuyo genoma de referencia no está completamente caracterizado se requiere un ensamblaje *de novo* del transcriptoma. En este enfoque las lecturas se ensamblan en transcritos sin ayuda de este genoma de referencia, lo cual se especialmente útil para el descubrimiento de nuevos transcritos y la identificación de splicings alternativos. El alineamiento sobre las secuencias (de referencia o *de novo*) se realiza utilizando algoritmos de alineamiento. A la vez también se realiza un conteo de las veces que cada lectura se alinea sobre un gen o transcrito. Como resultado se obtiene una matriz de cuentas de las lecturas que refleja la expresión génica relativa de cada gen en la muestra analizada. Los valores de esta matriz tienen que ser normalizados. Esta normalización puede realizarse mediante varios algoritmos, de los cuales lo más utilizados son los que utilizan RPKM/FPKM (*Reads/Fragments Per Kilobase of transcript per Million mapped reads*) (25) y TPM (*Transcripts Per Million*) (26). Estos métodos normalizan la abundancia de lecturas teniendo en cuenta la longitud del gen y el número total de lecturas mapeadas en la muestra, lo que permite comparar la expresión génica entre diferentes genes y condiciones. La normalización por TPM facilita la comparación entre distintos datos ya que la suma de todos los valores de TPM es la misma en todas las muestras. Esto hace que los valores de TPM presenten un nivel de expresión relativo que, en principio, es comparable entre distintas muestras.

La cuantificación de la expresión génica nos permite realizar análisis de expresión diferencial para identificar los genes que muestran cambios significativos en su expresión entre diferentes condiciones experimentales. Con esto se pueden identificar genes candidatos que están implicados de manera significativa en respuesta infecciones, etapas de desarrollo, diferencias en tejidos específicos u otras condiciones biológicas de interés. Estos análisis diferenciales se basan en métodos estadísticos que evalúan la significancia de los cambios de expresión.

1.3.3. Herramientas principales

En la realización de todo análisis bioinformático de RNA-Seq existen una serie de herramientas, programas y pipelines comúnmente usados. Entre las herramientas más populares se incluyen Trimmomatic, fastp, SeqTrim o CutAdapt para el procesamiento de los datos (limpieza de lecturas de baja calidad, eliminación de adaptadores, corte de nucleótidos

finales o iniciales, etc.); HISAT2, GSNAP o STAR para el alineamiento de las lecturas; featureCounts, Cufflinks o StringTie para la cuantificación de la expresión génica; y DESeq2, edgeR y limma para el análisis de expresión diferencial (27–36).

Por otro lado, existen plataformas que ofrecen un flujo de trabajo integral que combina varias etapas del análisis en un único flujo de trabajo coherente y reproducible. Un ejemplo notable es el de la plataforma Galaxy (37), que permite realizar todo este proceso de análisis en una sola plataforma o programa.

En conclusión, la bioinformática aporta los métodos necesarios para procesar, ensamblar y cuantificar los datos de RNA-Seq, revelando los procesos metabólicos subyacentes e impulsando el conocimiento científico en especies como la papaya.

1.4. Portales genómicos y atlas de expresión

Los portales genómicos son una herramienta central en la investigación biológica. En ellos se guarda y organiza información biológica de una o varias especies y se pone a disposición de investigadores y otras entidades. Dentro de la investigación en plantas existen portales generalistas como Phytozome (38) que reúnen información de un gran número de especies de plantas, y portales específicos de especies como puede ser MangoBase (39), un portal basado también en EasyGDB.

Dentro de estos portales existen también una serie de herramientas útiles para la investigación como lo son BLAST, JBrowse, herramientas de búsqueda y los atlas de expresión.

Los atlas de expresión son herramientas que permiten integrar, estandarizar y visualizar datos transcriptómicos a gran escala. Estos datos a menudo son obtenidos gracias a experimentos de RNA-Seq, procedentes de varios tejidos, diferentes estadios de desarrollo y condiciones como estreses bióticos o abióticos. La importancia de esta herramienta radica en su capacidad de unificar y estructurar gran cantidad de datos que normalmente se encuentran dispersos y, a su vez, permitir la exploración *in silico* de perfiles de expresión de la especie estudiada. Con esto se facilita la identificación de genes candidatos llegando a optimizar drásticamente recursos económicos y temporales en proyectos de biología molecular y programas de mejora genética.

En este sentido, aunque hay muchos ejemplos de portales genómicos especializados en plantas, sigue existiendo una gran desorganización y dispersión de la información relativa a


varias especies, como puede ser el caso de la papaya. Hasta la fecha de la publicación de este trabajo, no existe ningún portal centrado en papaya y, a su vez, tampoco un atlas de expresión que pueda ser utilizado de forma pública.

1.5. IHSM Subtropicals

El Instituto de Hortofruticultura Subtropical y Mediterránea (IHSM) “La Mayora” es un centro de investigación en plantas, creado para unir los esfuerzos de los grupos de la preexistente Estación La Mayora del Consejo Superior de Investigaciones Científicas (EELM-CSIC) y grupos de varios departamentos de la Facultad de Ciencias de Málaga (UMA). Con ello se pretendía potenciar y coordinar más eficientemente la investigación científica en horticultura intensiva y fruticultura subtropical que venía desarrollándose en las dos entidades. El centro tiene más de 60 años de historia y una estación experimental de 50 Ha. Localizado en la provincia de Málaga, contiene una colección de variedades de especies subtropicales adaptadas para el cultivo en el ambiente mediterráneo local, fuera de los trópicos. El banco de germoplasma del IHSM contiene la mayor colección de chirimoya del mundo, y cuenta con más de 100 accesiones de aguacate y más de 80 de mango, así como otras especies entre las que se incluye la papaya.

Con la finalidad de clasificar y organizar toda la información generada en el centro se creó la base de datos del IHSM Subtropicals, que provee de herramientas bioinformáticas y datos genómicos de especies subtropicales procedentes del estudio realizado en el IHSM.

Esta base de datos fue creada sobre la base de EasyGDB, una herramienta diseñada para crear portales genómicos de manera sencilla y fácil de mantener, desarrollada también en el mismo grupo en el IHSM (40) (**Figura 2**).



Welcome to Easy GDB

Subtitle h2

Subtitle h3

This is a template to write your own welcome page. Please, follow the instructions to create your own custom_text folder and include the path in the configuration file.

Lorem ipsum dolor sit amet consectetur adipiscing elit mus nisi vel risus semper sagittis vitae, luctus platea quisque cum nascetur sem ligula leo magnis cursus cubilia pulvinar. Habitasse praesent platea nunc pharetra laoreet etiam congue proin, nostra vehicula nec quis iaculis molestie integer diam viverra, primis nullam gravida massa tempor curae metus. Vitae vivamus nascetur eros mus viverra nostra fames sagittis faucibus donec, cubilia interdum volutpat augue nisl libero fermentum proin quisque, mollis erat facilisi posuere rutrum luctus quis imperdiet pretium.

Risus sollicitudin facilisis integer luctus hendrerit aliquet natoque senectus suspendisse, parturient facilisi laoreet tempor hac cum mi egestas ridiculus, accumsan lacinia inceptos diam commodo per bibendum nullam. Morbi blandit a suspendisse quis nascetur dignissim tellus, ante ad curabitur leo mauris taciti sollicitudin habitasse, diam pharetra euismod tristique aliquet nam. Dis nascetur vivamus justo libero platea interdum feugiat tellus, ad commodo nec etiam volutpat imperdiet viverra, habitasse suspendisse arcu porttitor lacinia iaculis aenean.

Figura 2. Previsualización base de EasyGDB

Dentro de las posibilidades que permite EasyGDB está la de incorporar a la base de datos creada un atlas de expresión con los datos procedentes de experimentos de RNA-Seq. En el caso del IHSM Subtropicales existen atlas de expresión de varias especies como las del género *Annonas*, el cacao y pawpaw.

1.5.1. Otros ejemplos de atlas de expresión

Gracias a EasyGDB se han podido generar varios atlas de expresión funcionales que han sido publicados y están siendo utilizados por grupos de investigación de todo el mundo. Algunos ejemplos son:

- [OliveAtlas](#) (41): atlas de expresión de olivo.
- [SkeletalAtlas](#): atlas de expresión de tejido esquelético en humano y ratón.
- [AvoBase](#): portal genómico de aguacate.
- [MangoBase](#) (42): portal genómico de mango.
- [MAdLand](#) (43): portal genómico de especies de plantas sin semillas.

Esto da muestra de la importancia que tiene esta herramienta para diferentes áreas de investigación, no solo en plantas sino en otras especies como humanos, ratones, plantas sin semillas, etc.

1.6. Justificación del estudio

Pese a todo lo expuesto anteriormente y habiendo resaltado la importancia que tiene a día de hoy la papaya (tanto de forma económica como científica) la información transcriptómica disponible permanece dispersa en diferentes bases de datos o proyectos no relacionados entre sí. Hasta donde se ha podido comprobar, este atlas constituye uno de los primeros atlas de expresión públicos especialmente centrados en papaya. La falta de estos atlas retrasa y entorpece la investigación de este cultivo. Por ello, el presente estudio pretende suplir esta carencia desarrollando un atlas basado en datos públicos de RNA-Seq e integrado en el portal genómico de especies subtropicales “IHSM Subtropicals”, con el fin de facilitar la exploración y reutilización de la información transcriptómica de *Carica papaya*.

2. Objetivos

A continuación se detallan las metas propuestas para el desarrollo de este Trabajo Fin de Máster.

2.1. Objetivo general

El objetivo general con este trabajo de fin de máster consiste en desarrollar un atlas de expresión de interés para la investigación de la especie *Carica papaya* (Papaya). Este atlas de expresión estará basado en análisis de datos de RNA-Seq disponibles de manera pública. Con él se pretende unificar y organizar la información dispersa en bases de datos públicas en un portal único y de acceso libre para la investigación.

2.2. Objetivos específicos

- Diseñar un pipeline reproducible para el flujo de trabajo de RNA-Seq.
- Procesar distintos datasets disponibles de forma pública en el ENA.
- Analizar posibles contaminaciones en secuencias y posterior descontaminación, utilizando el servicio de supercomputación Picasso.
- Generar, a partir de los datos procesados de datasets, matrices de expresión normalizadas.
- Integrar los datos resultantes en forma de matrices en el portal genómico del IHSM Subtropicals, basado en EasyGDB.
- Evaluar el atlas de expresión mediante casos específicos de uso como puede ser la exploración de los patrones de expresión de papaya.

3. Materiales y métodos

En este tercer apartado se describe detalladamente la metodología y las herramientas empleadas para llevar a cabo dicho proyecto.

3.1. Recursos computacionales

Para este estudio se contó con un PC ofrecido por el IHSM que cuenta con sistema operativo Ubuntu 24.04.2 LTS. También con un PC personal que cuenta con sistema operativo Windows 11 Home, 16 GB de memoria RAM, procesador Intel® Core™ i7-10750H CPU @ 2.60GHz (2.59 GHz). Con estos dos PCs se realizó la mayoría del tratamiento de datos de RNA-Seq.

Por otra parte, debido a la gran cantidad de datos requeridos y a la capacidad computacional necesaria para su tratamiento, también se contó con el sistema de supercomputación de la Universidad de Málaga (UMA), el supercomputador Picasso (SCBI, s. f.).

Para poder utilizar los recursos de este supercomputador dispone de un sistema de colas por el cual los trabajos a realizar son enviados, indicando qué recursos son necesarios. Una vez hecho esto Picasso se encarga de asignarlos cuando sea posible.

La forma en la que se trabaja en Picasso es a través de un servidor de acceso basado en un intérprete de comandos seguro, o SSH (*Secure Shell*). Una vez dentro, el propio supercomputador cuenta con un sistema de archivos por el cual lanzar los *scripts* o almacenar los datos con los que se trabajan.

El entorno de trabajo de Picasso está basado en Bash (*Bourne-again Shell*), un intérprete de comandos que facilita la comunicación directa del usuario con la máquina. Dentro de Picasso encontramos una amplia variedad de programas instalados, entre los cuales se encuentran herramientas que se utilizaron en los distintos análisis. Para poder utilizarlos es necesario previamente cargarlos en la RAM del supercomputador. Algunos de los programas no se encuentran instalados en un inicio y deben instalarse por el propio usuario o por el servicio técnico de Picasso.

Tanto para el trabajo local como el trabajo remoto en Picasso, fue necesario crear o adaptar *scripts* con extensión .sh (que indica que el lenguaje utilizado es Bash) con los que realizar todo el tratamiento de datos.

3.2. Obtención de los datos de RNA-Seq

El objeto de estudio son lecturas de RNA-Seq sin procesar (*raw_data*) disponibles en bases de datos de acceso libre. Para ello se buscó tanto en el *European Nucleotide Archive* (ENA), perteneciente al *European Bioinformatics Institute* (EBI), como en el *Sequence Read Archive* (SRA), perteneciente al *National Center for Biotechnology Information* (NCBI).

La selección de los distintos dataset utilizados para la conformación del atlas fue realizada teniendo en cuenta los temas tratados en los distintos estudios en los que se enmarcan, buscando tener una visión lo más amplia posible. La selección final se presenta en la **Tabla 1**.

Tabla 1. Tabla resumen con la información de los distintos datasets tratados

<i>Bioproject</i>	<i>Nombre del dataset</i>	Nº de condiciones experimentales	Fuente
<i>PRJNA528193</i>	<i>C. papaya</i> fruit ripening induced by ethylene	5	Soares et al., 2021
<i>PRJNA880626</i>	<i>C. papaya</i> fruit ripening of two varieties with different flavour profile	5	Zhou et al., 2024
<i>PRJNA687615</i>	<i>C. papaya</i> pistil development	6	Liao et al., 2022
<i>PRJNA565901</i>	<i>C. papaya</i> male, female and hermaphrodite flowers buds at pre- and post-meiosis	6	Zerpa-Catanho et al., 2019
<i>PRJNA549650</i>	<i>C. papaya</i> gynoecium morphogenesis of male, female and hermaphrodite flowers induced by auxin	6	Zhou et al. 2019
<i>PRJNA713527</i>	<i>C. papaya</i> callus and shoot regeneration	5	Zhao et al. 2021
<i>PRJNA470602</i>	<i>C. papaya</i> drought stress	9	Gamboa-Tuz et al. 2018
<i>PRJNA591254</i>	<i>C. papaya</i> response to Papaya Leaf-Distortion Mosaic Virus (PLDMV) and Chitosan-N	3	An et al. 2020

Una vez realizada la selección se procedió a la descarga de los datos. Para ello se buscó la página de [ENA](#) correspondiente al Bioproject de interés y se realizó la descarga usando el script Bash (Anexo A.1) que el propio ENA genera cuando seleccionamos la opción “Download All” en la sección “Generated FASTQ files: FTP”. Los datos descargados tienen un formato FASTQ

comprimido como “fastq.gz” (44). Este formato contiene las lecturas de nucleótidos y la calidad asociada a cada uno de estos, medida en *Phred Score* (Q_{PHRED}) calculado como: $Q_{PHRED} = -10 \times \log_{10}(P_e)$.

Existen diferentes versiones del formato FASTQ que varían dependiendo de la codificación usada para medir la calidad. En este estudio, los datos obtenidos desde las bases de datos públicas ya se encontraban estandarizados en la codificación de calidad Sanger (Phred +33), que es el formato estándar actual utilizado por las plataformas de secuenciación de Illumina. En este formato, cada nucleótido tiene asociado un valor de calidad en un rango de 0-40 que a su vez está codificado mediante caracteres del código ASCII comprendidos entre 33-77. En la **Tabla 2** se muestra cómo se asignan los caracteres en este código dependiendo de la probabilidad de error en la asignación de una base en escala logarítmica.

Tabla 2. Niveles de calidad medidos en QPHRED y su relación con la probabilidad de error de la base

Q_{PHRED}	Probabilidad de error	Precisión
10	1 de cada 10	90%
20	1 de cada 100	99%
30	1 de cada 1000	99,9%
40	1 de cada 10000	99,99%

Cada dataset tiene asociados unos metadatos necesarios para conocer aspectos como el nombre de las muestras, las diferentes condiciones experimentales o el número de replicas biológicas. Estos metadatos se pudieron obtener mediante un *script* (Anexo A.2) en Python con el cual se obtuvo toda esta información y se pudo almacenar en una tabla (**Tabla 3** y Anexo B) para su consulta en los pasos siguientes.

Tabla 3. Visualización de tabla de metadatos para un dataset en concreto

Bioproject	Run name	Sample	Experimental contition
PRJNA591254	SRR10537358	the stage of growing leaf	B3
PRJNA591254	SRR10537359	the stage of growing leaf	B2
PRJNA591254	SRR10537360	the stage of growing leaf	B1
PRJNA591254	SRR10537361	the stage of growing leaf	CG3
PRJNA591254	SRR10537362	the stage of growing leaf	CG2
PRJNA591254	SRR10537363	the stage of growing leaf	CG1
PRJNA591254	SRR10537364	the stage of growing leaf	CK3
PRJNA591254	SRR10537365	the stage of growing leaf	CK2
PRJNA591254	SRR10537366	the stage of growing leaf	CK1

3.3. Obtención del genoma de referencia

El genoma de referencia de papaya utilizado para este estudio se trata del genoma publicado por Yue et al. sobre la variedad “SunUp”. Esta es una variedad transgénica obtenida mediante biobalística a partir de la variedad comercial “Sunset”. El vector introducido contiene el gen de la proteína capsídica del del PRSV HA 5-1 y la variedad resultante (“SunUp”), al ser resistente a este patógeno, se ha convertido en la variedad más extendida y comercializada (24). Por este motivo se decidió usar este como el genoma de referencia.

3.4. Pipeline bioinformático

El pipeline del trabajo se puede sintetizar en un diagrama de flujo (**Figura 3**). Este diagrama muestra los programas utilizados y los datos resultantes de cada uno de ellos, así como los resultados finales. A su vez incluye como resultado final la creación del atlas de expresión.

Para la correcta representación de dicho diagrama se siguió un modelo estandarizado en el que se pueden distinguir lo siguientes símbolos:

- Óvalos: representan el inicio y fin de un proceso.
- Rectángulo: cualquier tipo de operación.
- Rectángulo curvado en la base: generación y obtención de documentos y datos.




Figura 3. Diagrama de flujo del trabajo realizado

El análisis bioinformático de este trabajo se hizo siguiendo un pipeline optimizado en el grupo de investigación y comúnmente usada en este tipo de procedimientos. Los scripts fueron adaptados para poder ser ejecutados de manera local ya que en un principio estaban pensados para ser ejecutados por el sistema Picasso. El pipeline sigue una serie de pasos que a continuación se describe.

3.4.1. Creación de un entorno de trabajo

Antes de empezar con el pipeline, y debido a que se trabajó en local la mayoría del tiempo, se creó un entorno de trabajo en el que se incluyó todos los programas necesarios para el posterior tratamiento de datos. Este entorno se creó con Mamba tal y como aparece en el Anexo A.3.

En pasos posteriores se activó el entorno de trabajo al inicio del script y se desactivó después de haber ejecutado el programa para evitar posibles fallos.

3.4.2. Control de calidad

En primer lugar, se analizó la calidad de las lecturas brutas descargadas. Estas lecturas pueden tener errores de secuenciación que interesa eliminar o procesar antes de seguir con el trabajo, para que este no se vea perjudicado. Para ello se decidió utilizar el programa FastQC (45) en su versión 0.12.1 (Anexo A.4) el cual es una aplicación bioinformática con diferentes módulos que permiten atender diferentes aspectos de las lecturas. A continuación, se describen los módulos a los que se atendió para comprobar la calidad de las lecturas:

- *Per Base Sequence Quality*: genera gráficas que permiten visualizar la calidad media a lo largo de las lecturas.
- *Per Base Sequence Content*: muestra las proporciones de cada nucleótido presentes a lo largo de la lectura.
- *Per Sequence CG Content*: es un módulo encargado de medir la proporción de citosina y guanina (C y G) encontradas en cada lectura. Esta proporción está correlacionada con posibles contaminaciones en lecturas.
- *Sequence Duplication Levels*: muestra de forma gráfica qué lecturas han sido duplicadas, en qué porcentaje y cuál ha sido el número de duplicaciones.

- *Overrepresented Sequences*: gráfica que muestra qué secuencias están sobrerrepresentadas, y en qué porcentaje con respecto del total.
- *Adapter Content*: crea una gráfica en la que se muestra si los datos contienen un alto número de secuencias de adaptadores procedentes de la secuenciación, y por lo tanto están contaminadas con ellos.

Con cada una de las secuencias analizadas con FastQC se generó un informe individual. El conjunto de informes se combinó y ordenó utilizando otro software llamado MultiQC en su versión 1.33 (46) (Anexo A.4). El informe final y único sirvió para comprobar el estado y calidad inicial de las lecturas de los distintos datasets. Con ello se pudo determinar que todos ellos cumplían unos valores de calidad lo suficientemente altos para seguir con el resto del procesado.

3.4.3. Descontaminación de las lecturas

Observando los datos generados por FastQC y compilados con MultiQC, atendiendo a la gráfica de *Per Sequence CG Content*, se pueden encontrar lecturas que estén contaminadas con secuencias de otras especies. En caso de que así sea, se pueden utilizar programas complementarios que permiten hacer una clasificación taxonómica de estas secuencias y discriminar todas aquellas que no interesen ya que pertenecen a especies como, por ejemplo, bacterias. Este paso se aplica solo a aquellos datasets en los que el informe de calidad sugirió una posible contaminación. El programa utilizado para ello es kraken2 (versión 2.1.5). Este proceso se realiza en dos pasos:

1. Primero se crea una biblioteca a partir de una base de datos que kraken utilizará para clasificar taxonómicamente las secuencias. En el caso de este estudio se utilizó la base de datos de SILVA, una base de secuencias de RNA ribosómicos. El motivo de esta decisión es que esta base de datos es relativamente pequeña comparada con el resto de bases de datos que engloban todas las secuencias de microorganismo y otras especies. Para este se creó un primer script (Anexo A.5), en el cual se indicó qué base de datos se utilizó generar la librería.
2. El siguiente paso consiste en la clasificación de las secuencias y su discriminación. Esto lo realiza el propio software de kraken, al cual se tiene que añadir una serie de parámetros en el script (Anexo A.6), para que cree unos nuevos archivos de lectura

limpios de todas aquellas secuencias clasificadas como pertenecientes a otras especies no relacionadas.

Una vez obtenidas las secuencias descontaminadas se vuelven a realizar el paso anterior, el control de calidad con FastQC y MultiQC, para comprobar si la calidad ha mejorado y poder seguir con el procesamiento de las lecturas.

3.4.4. Procesado de las lecturas

El siguiente paso después de haber analizado la calidad de las lecturas inicial es el procesado de las mismas. Con esto se pretende eliminar todas aquellas que no lleguen a una calidad mínima y también eliminar secuencias que puedan coincidir con adaptadores. Para ello se utilizó el software FastP en su versión 1.1.0 (28) (Anexo A.7).

FastP tiene una serie de parámetros configurables dependiendo de lo que se precise a la hora de tratar las lecturas. En el caso de este estudio se realizó este tratamiento de la siguiente manera:

- Se eliminaron las lecturas con una calidad media inferior a 15 en un rango de 4 nucleótidos.
- Se recortaron los 15 primeros nucleótidos de todas las lecturas debido a la baja calidad que suelen tener en comparación con el resto.
- Se eliminaron las lecturas con una longitud inferior a 36 nucleótidos por ser demasiado cortas.
- Se recortaron los nucleótidos con calidad inferior a 3 tanto al principio como al final de la secuencia.
- Se eliminaron las secuencias que correspondan a adaptadores que el propio software reconoce. No hace falta añadirle una lista externa como es el caso de otros programas similares.
- Se eliminaron las lecturas que contuvieran secuencias de polinucleótidos, por ejemplo, poliadeninas (polyA).

Realizada la limpieza con FastP se volvió a hacer un control de calidad de las lecturas con FastQC y MultiQC. Se aseguró que la calidad había aumentado y se habían eliminado las lecturas no deseadas. Existen otros programas utilizados comúnmente para este propósito, como Trimmomatic. Sin embargo, en este estudio se decidió usar FastP por la posibilidad que

este ofrece para eliminar secuencias con polinucleótidos que estaban siendo muy difíciles de procesar.

3.4.5. Alineamiento de las lecturas

Las lecturas se alinearon sobre el genoma de referencia. Para ello se utilizó el software HISAT2 (*Hierarchical Indexing for Spliced Alignment of Transcripts 2*) en su versión 2.2.1 (31) (Anexo A.8 y Anexo A.9). Este software utiliza un esquema de indexado pasado en el índice FM (*Full-text Minute-space*) (47) y en la transformada de Burrows-Wheeler (48). Se decidió usar este programa en vez de otros, como por ejemplo STAR, debido que el flujo de trabajo ya había sido optimizado de esta forma por el grupo.

HISAT2 primero genera un índice a partir del genoma de referencia para que, en el paso de alineamiento propiamente dicho, encuentre mediante algoritmos las secuencias en el genoma más rápidamente.

Para este proceso tenemos dos scripts distintos dependiendo de si los datasets tienen lecturas *Paired Ends* (Anexo A.8) o *Single Ends* (Anexo A.9).

Una vez hecho el alineamiento con HISAT2 se utilizó un segundo software con el que se filtraron, ordenaron y convirtieron los alineamientos en formato BAM. La herramienta utilizada para esto es SAMtools (49) (Anexo A.8 y Anexo A.9) en su versión 1.17.

3.4.6. Conteo de las lecturas

Una vez hecho el alineamiento de las lecturas se llevó a cabo el conteo de estas por cada gen. Para ello se utilizó la herramienta featureCounts (50) (Anexo A.10 y Anexo A.11) en su versión 2.1.1. Con esto se pretende conseguir cuantificar la expresión génica de genes de interés en las muestras.

En esta ocasión también se adaptaron dos scripts distintos según si las lecturas eran pareadas (Anexo A.10) o no (Anexo A.11). Otros parámetros utilizados permiten excluir las lecturas que se asignan a múltiples loci y contar únicamente las lecturas que se alinean a exones. Un punto importante es asignar el archivo GFF (*General Feature Format*) del genoma de referencia que contiene las anotaciones de los genes de interés.

Como archivo de salida de este programa se obtuvo un fichero tabulado que contiene una matriz de cuentas. En esta matriz muestra la cantidad de lecturas que se asignan a cada gen en cada muestra de RNA-seq.

3.4.7. Normalización de los datos

Las matrices finales fueron normalizadas a TPM (*Transcripts Per Million*), corrigiendo por la longitud génica y por la profundidad de secuenciación de cada muestra. Se decidió utilizar tablas con valores TPM porque este formato es el que requiere la herramienta del atlas de expresión perteneciente a EasyGDB para poder ser leída correctamente.

Para poder realizar esta normalización primero se tuvo que crear un *script* en lenguaje Bash que permitiera generar dos archivos a partir de la matriz, uno con la longitud de los genes y otro con las columnas con los conteos (Anexo A.12).

Para esta normalización se desarrolló un *script* (Anexo A.13) en lenguaje R en su versión 4.4.2 (51). En este script se utilizó la función `convertCounts` del paquete `DGEobj.utils` (52), en su versión 1.0.6, que permite calcular los TPM y como salida devuelve un archivo de texto que se utilizó en el atlas.

3.4.8. Formateo de nombre y cambio de orden

Antes de poder crear el atlas de expresión se tuvo que preparar los archivos obtenidos en el último paso y cambiar el formato de los nombres y el orden de los mismos para que se adecuaran a lo que se mostraba en la información de los distintos datasets. Para ello, se usó la tabla de metadatos (Anexo B) en la cual se asigna el nombre de una lectura con la condición experimental que representa dentro del restudio. Y, con base en esta tabla, se desarrollaron dos *scripts* en R que permiten limpiar y cambiar los nombres y ordenarlos para facilitar su visionado y entendimiento en el atlas final (Anexo A.14).

3.5. Creación del atlas de expresión

El atlas está destinado a pertenecer al portal genómico [IHSM Subtropicals DB](#), un portal desarrollado gracias a la herramienta de creación de portales genómicos EasyGDB (40). Para poder usar esta herramienta clonamos los recursos presentes en GitHub ([GitHub – noefp/easy_gdb](#)) en un contenedor Docker (53). Dentro de este repositorio clonado se pueden modificar distintos archivos que permitirán personalizar el atlas. Se modificaron los archivos

.php y .json para añadir una breve descripción de cada uno de los datasets, y se adjuntaron figuras relevantes para la mayor comprensión del estudio del cual se obtuvieron los datos. En este proceso de personalización también se pueden seleccionar las diferentes funcionalidades disponibles para el atlas, tales como la posibilidad de presentar gráficas, heatmaps, expression cards comparativas con los datos de cada uno de los datasets.

Los datos de expresión en formato TPM fueron depositados en la ruta correspondiente “scr/expression_data”. Esta ruta está enlazada al resto de funcionalidades y herramientas presentes en EasyGDB, las cuales toman la información de los archivos creados para las representaciones gráficas y visuales anteriormente descritas.

Todo este trabajo de creación y personalización pudo realizarse gracias a la visualización local del portal a través de la dirección localhost:8000/easy_gdb, que permite Docker. Una vez comprobado el correcto funcionamiento e implementación de los datos de manera local, todo ello se publicó en la base de datos IHSM Subtropicals DB.

3.6. Creación de archivos de anotaciones

Como paso complementario a todo lo anterior se generaron los archivos de anotaciones necesarios. Estos archivos de anotaciones son archivos de texto en forma de tabla donde se muestran en forma de tabla cómo se relacionan los nombres de las secuencias presentes en el atlas con los nombres que podemos encontrar para dichas secuencias en otras bases de datos de interés como Araport11, SwissProt, TrEMBL, NCBI (non-redundant) e InterPro.

Para ello se utilizó el programa Diamond en su versión 2.1.24 (54) que realiza un BLASTP sobre todas las secuencias de aminoácidos que se encontraron en el archivo fasta que se obtuvo a la vez que el genoma de referencia. Este programa hace BLASTP sobre distintas bases de datos y dividimos estas búsquedas distinguiendo entre una búsqueda sobre las bases de datos de Araport11, SwissProt, TrEMBL (Anexo A.15); y una búsqueda sobre la base de datos del NCBI Non-redundant (Anexo A.16). Por otro lado, se usó el programa InterProScan5 en su versión 5.67 (55) (Anexo A.17) que funciona de manera similar a Diamond, pero sobre la base de datos de InterPro. Estos programas generan archivos a partir de los cuales se crearon los archivos de anotaciones.

Dado que la generación detallada de archivos de anotación excede el objetivo principal del presente trabajo, en apartados posteriores se mostrará únicamente los resultados finales obtenidos.

4. Resultados

Los resultados se han dividido en dos partes, una primera en la que se exponen los resultados obtenidos a lo largo del pipeline bioinformático buscando procesar los datos de los datasets seleccionados y su incorporación en el atlas de expresión; y una segunda parte, de gran importancia, que muestra el funcionamiento real del atlas de expresión construido. En esta parte, mediante un ejemplo, se da un caso real de búsqueda *in silico* de posibles genes candidatos relacionados con la expresión diferencial entre flores masculinas y femeninas en *Carica papaya*.

Por último, se da una pequeña muestra de los resultados que se obtuvieron a la hora de realizar los archivos de anotaciones.

4.1. Unificación, centralización y estandarización de los datos

4.1.1. Datos iniciales

Las lecturas usadas para este trabajo se pueden agrupar en BioProject gracias a los metadatos que encontramos en la **Tabla 4** (Anexo B). Así obtenemos 8 BioProjects con un total de 47 muestras (**Tabla 4**) (18,56–62). Estos 8 BioProjects seleccionados abarcan estudios en diferentes tejidos, diferentes condiciones de desarrollo y condiciones experimentales.

Tabla 4. Conjunto de datos obtenidos

<i>Bioproject</i>	Muestras	Nº de replicas biológicas	Publicación	Condiciones experimentales
PRJNA528193	5	3	Systems biology applied to the study of papaya fruit ripening: The influence of ethylene on pulp softening	Maduración de fruto
PRJNA880626	5	3	Identification and Validation of Key Genes Related to Preferred Flavour Profiles in Australian Commercial Papaya (<i>Carica papaya</i> L.)	Dos variedades de papaya en estado maduro e inmaduro
PRJNA687615	6	3	Gene regulation network analyses of pistil development in papaya	Carpelo en diferentes estados de desarrollo
PRJNA565901	6	2	Differential gene expression among three sex types reveals a MALE STERILITY 1 (CpMS1) for sex differentiation in papaya	Flores de diferentes tipos sexuales
PRJNA549650	6	3	Auxin regulation involved in gynoecium morphogenesis of papaya flowers	Morfogénesis del gineceo
PRJNA713527	5	3	Auxin and cytokinin mediated regulation involved in vitro organogenesis of papaya	Regeneración de tallos y callos
PRJNA470602	9	2	Transcriptomics and co-expression networks reveal tissue-specific responses and regulatory hubs under mild and severe drought in papaya (<i>Carica papaya</i> L.)	Hojas, savia y raíces bajo estrés hídrico
PRJNA591254	3	3	Gene expression profiling of papaya (<i>Carica papaya</i> L.) immune response induced by CTS-N after inoculating PLDMV	Hojas bajo la infección de un virus

Se aplicó un control de calidad con FastQC y MultiQC, tras los cuales se obtuvo a modo de resumen la calidad de lecturas únicas y duplicadas presentes en cada grupo de datos. Todos estos archivos los podemos encontrar en el Anexo B. Los informes generados con estas herramientas ayudan a ver de manera general la calidad de los datos. En la **Figura 4** se pueden observar una de las gráficas pertenecientes al archivo generado por MultiQC del BioProject PRJNA565901. En ella se representa la calidad a lo largo de las posiciones de las distintas lecturas. La calidad de estas es más baja en las primeras posiciones, aumenta hasta su máximo alrededor de las 12 pares de bases y disminuye paulatinamente manteniéndose siempre en rangos aceptables (franja verde). En los distintos informes generados para el resto de BioProjects, la calidad representada de esta forma fue similar o superior, pasando todas el corte de calidad en este aspecto.




Figura 4. Gráfica “Per Base Sequence Quality Plot” de la calidad de las lecturas sin procesar del BioProject PRJNA565901 obtenida con MultiQC

En la **Figura 5** se observa otro tipo de información sobre la calidad de las lecturas, representada mediante el gráfico “Per Base Sequence Content”. Se aprecia que en los primeros 12 nucleótidos estas proporciones se distorsionan, lo cual puede ser un signo de baja calidad. El resto de informes generados para el resto de BioProjects mostraron resultados similares.




Figura 5. Gráfica “Per Base Sequence Content” de la calidad de las lecturas sin procesar del BioProject PRJNA470602 obtenida con MultiQC

Las lecturas brutas obtenidas con Illumina presentaron adaptadores. Esto se puede observar atendiendo a la gráfica “Adapter Content” (**Figura 6**). Al igual que en los parámetros anteriores se observó que todos los conjuntos de lecturas pasaron el control de calidad.




Figura 6. Gráfica “Adapter Content” de la calidad de las lecturas sin procesar del BioProject PRJNA713527 obtenida con MultiQC

Otro tipo de graficas que se generó en los informes MultiQC fueron las del tipo “Sequence Duplication Levels”, en las cuales se representan el porcentaje de lecturas duplicadas presentes en las muestras. Se puede observar en la **Figura 7** que las líneas que representan cada lectura están coloreadas en rojo o naranja indicando el porcentaje alto de lecturas duplicadas. Se observó altos niveles de duplicación de secuencias en la práctica totalidad de las muestras analizadas.




Figura 7. Gráfica “Sequence Duplication Levels” de la calidad de las lecturas sin procesar del BioProject PRJNA549650 obtenida con MultiQC

Otra grafica a la que se atiende para comprobar la calidad de las lecturas es la del tipo “Overrepresented sequences”. En ella se representan secuencias que se encuentran sobrerrepresentadas en las lecturas. Como se observa en la **Figura 8**, se encontraron sets de datos con secuencias de polinucleótidos (por ejemplo, polyG) sobrerrepresentadas, además de otras secuencias pertenecientes a adaptadores u genes con una gran expresión, como puede ser el de la RuBisCO.

Overrepresented sequence	Reports ▾	Occurrences ▾	% of all reads
GGG	5	306979	0.0247 %
CCCAGGCAGACGTGCCCTCAGCCGGATGGCGTCGAACCTGCGTTC	2	182993	0.0147 %
NNN	4	154117	0.0124 %
CGGCAACGGATATCTCGGCTCTCGCATCGATGAAGAACGTAGCGAAATGC	2	124506	0.0100 %
TGGG	1	110446	0.0089 %
CTCGGCTCTCGCATCGATGAAGAACGTAGCGAAATGCGATACTTGGTGTG	2	101141	0.0081 %
CGGATATCTCGGCTCTCGCATCGATGAAGAACGTAGCGAAATGCGATACT	2	85022	0.0068 %
GATCGGAAGAGCACACGTCTGAACTCCAGTCACAGTCAA CAATCTCGTAT	1	64780	0.0052 %
GATCGGAAGAGCACACGTCTGAACTCCAGTCACGATCAGATCTCGTATGC	1	56854	0.0046 %
GATCGGAAGAGCACACGTCTGAACTCCAGTCACATCACGATCTCGTATGC	1	42730	0.0034 %
GATCGGAAGAGCACACGTCTGAACTCCAGTCACGTCCGCACATCTCGTAT	1	36329	0.0029 %

Figura 8. Gráfica “Overrepresented sequences” de la calidad de las lecturas sin procesar del BioProject PRJNA470602 obtenida con MultiQC

4.1.2. Lecturas contaminadas

Atendiendo a las gráficas “Per Sequence GC Content” mostradas en los informes generados por MultiQC se pudo observar que el conjunto de datos del BioProject PRJNA880626 generó una gráfica con líneas rojas y naranjas atribuibles a una contaminación de las muestras (**Figura 9**). El resto de conjunto de datos no mostraron tal contaminación.




Figura 9. Gráficas “Per Sequence GC content” de la calidad de las lecturas sin procesar de los BioProject PRJNA880626 (arriba) y PRJNA591254 (abajo) obtenidas con MultiQC

4.1.3. Lecturas procesadas

La calidad global de todos los conjuntos de datos mejoró después del procesamiento con FastP. Esto se puede comprobar atendiendo a los archivos presentes en el Anexo B.

Se observa en la **Figura 10** como la calidad de las lecturas mejoró en los extremos inicial y final. En la **Figura 11** se observa cómo se eliminó el sesgo observado en las primeras posiciones de las lecturas.




Figura 10. Gráfica “Per Base Sequence Quality Plot” de la calidad de las lecturas procesadas del BioProject PRJNA565901 obtenida con MultiQC




Figura 11. Gráfica “Per Base Sequence Content” de la calidad de las lecturas procesadas del BioProject PRJNA470602 obtenida con MultiQC

Se consiguió eliminar el contenido en adaptadores en un alto porcentaje, como se puede ver en la **Figura 12**, comparándolo con el mismo contenido presente en el mismo conjunto de lecturas antes del procesado (**Figura 6**).




Figura 12. Gráfica “Adapter Content” de la calidad de las lecturas procesadas del BioProject PRJNA713527 obtenida con MultiQC

Se pudo observar únicamente en el conjunto de datos pertenecientes al BioProject PRJNA565901 que la distribución de longitud de las lecturas disminuyó, presentando ahora distintos picos en distintas longitudes (**Figura 13**).




Figura 13. Gráfica “Sequence Length Distribution” de la calidad de las lecturas procesadas del BioProject PRJNA565901 obtenida con MultiQC

Las lecturas procesadas con FastP mostraron un porcentaje de lecturas con secuencias de polinucleótidos sobreexpresadas casi inexistente (**Figura 14**).

Overrepresented sequences by sample

 Help

The total amount of overrepresented sequences found in each library.

36 samples had less than 1% of reads made up of overrepresented sequences

Figura 14. Gráfica “Overrepresented sequences” de la calidad de las lecturas procesadas del BioProject PRJNA470602 obtenida con MultiQC

La descontaminación de las lecturas del BioProject PRJNA880626 no obtuvo los resultados esperados. Como se puede observar en la **Figura 15**, el contenido en secuencias contaminantes no solo no disminuyó, sino que parece haber empeorado.




Figura 15. Gráficas “Per Sequence GC Content” de la calidad de las lecturas descontaminadas y procesadas del BioProject PRJNA880626 (arriba); y solamente procesadas de los BioProject PRJNA470602 (abajo) obtenidas con MultiQC

El conjunto de datos del BioProject PRJNA880626 continuó usándose pese a la persistencia de la contaminación observada.

4.1.4. Lecturas alineadas a la referencia

El porcentaje de alineamiento de las lecturas sobre el genoma fue muy elevado, siendo siempre superior al 90%, salvo el caso del BioProject PRJNA880626 que mostró un porcentaje

en torno al 70% en algunas lecturas (**Tabla 5**, Material complementario **Anexo B**). Esto puede deberse a que las muestras originales tuvieran algo de contaminación o secuencias que no pertenecían a la papaya. A pesar de esta bajada, la cantidad de lecturas que sí se alinearon de forma única fue lo suficientemente alta como para poder contar la expresión de los genes sin perder información importante.

Después del alineamiento de las lecturas sobre el genoma de referencia de papaya, se obtuvieron los ficheros BAM con los alineamientos. Debido la magnitud de los datos no se han podido anexar en un repositorio en línea para su muestra.

Tabla 5. Tabla de porcentaje de lecturas alineadas del BioProject PRJNA470602

<i>Bioproject</i>	<i>Muestra</i>	<i>Lecturas crudas</i>	<i>Lecturas procesadas</i>	<i>Lecturas alineadas</i>
PRJNA470602	SRR7145699	32723799	28635768	95.30%
PRJNA470602	SRR7145700	31347259	27360153	93.72%
PRJNA470602	SRR7145701	32528720	28073699	95.82%
PRJNA470602	SRR7145702	39861192	34891990	95.87%
PRJNA470602	SRR7145703	42292905	37313948	96.23%
PRJNA470602	SRR7145704	43896258	38034752	96.00%
PRJNA470602	SRR7145705	47387690	40829801	93.79%
PRJNA470602	SRR7145706	36666468	32324104	91.44%

4.1.5. Atlas de expresión de *Carica papaya*

El principal objetivo de este trabajo era la creación de un atlas de expresión, lo cual se consiguió como se muestra en este apartado.

A partir de los archivos BAM se extrajeron las matrices de cuentas con featureCounts y se normalizaron en TPM con R. Estas matrices finales están disponibles en el **Anexo B**.

El atlas de expresión desarrollado con EasyGDB pudo ser visualizado de manera local a través de la dirección *localhost:8000/easy_gdb* (**Figura 16**), lo cual permitió comprobar el correcto funcionamiento de la herramienta y si los datos han sido generados correctamente.

Las distintas funcionalidades presentes en el atlas funcionaron de forma correcta. Entre estas funcionalidades se encuentran: la representación gráfica de los valores de expresión de los genes de interés, la visualización de resúmenes explicativos de los distintos artículos pertenecientes a cada BioProject y la tabla de equivalencias y anotaciones donde se relacionan los nombres de los genes propios del atlas con su equivalente en otras bases de datos.

El hecho de haber generado este atlas mejoró la situación actual de la información transcriptómica perteneciente a *Carica papaya*, la cual se encuentra en su mayoría no centralizada y disgregada en distintas bases de datos y proyectos no relacionados entre sí.

Después de comprobar el correcto funcionamiento del atlas, este se añadió a [IHSM Subtropicales DB](#). De esta manera también se pudo poner en funcionamiento el atlas de expresión para mostrar un caso práctico tal y como un grupo de investigación lo usaría con el fin de encontrar genes candidatos mediante un análisis *in silico*. Este proceso se muestra en el siguiente apartado.



Figura 16. Página de bienvenida de la base de datos local

4.2. Evaluación de patrones de expresión diferencial entre tipos sexuales en papaya utilizando el atlas de expresión.

Tras el desarrollo del atlas de expresión se decidió realizar un análisis del perfil de expresión génica de uno de los conjuntos de datos obtenidos, para así poder comprobar y mostrar la

utilidad del atlas. Para ello se centró la atención en el artículo asociado el BioProject PRJNA687615, de nombre “Gene regulation network analyses of pistil development in papaya” (58). Se decidió utilizar este conjunto de datos ya que era se consideró uno que podía mostrar bien todas las funcionalidades del atlas, con imágenes ilustrativas, grupos de muestras bien definidos y una información de los genes bien estructurada dentro del artículo.

De este dataset se tienen lecturas correspondientes a 3 muestras tomadas en distintos estadios de desarrollo floral pertenecientes a plantas femeninas y masculinas, con 3 réplicas biológicas por cada una, haciendo un total de 18 muestras.

En primer lugar, se decidió analizar las relaciones entre los conjuntos de datos para así poder comprobar la fiabilidad del diseño experimental. Gracias a un script en R (Anexo A.18) diseñado para realizar distintos análisis de reducción de la dimensionalidad (MDS, ICA, t-SNE, PCA y UMAP) se obtienen 5 gráficos distintos que permiten observar la distribución de los datos (**Figura 17**).




Figura 17. Gráficas generadas con distintos métodos de reducción de la dimensionalidad

En la **Figura 17** se observa como todos los métodos consiguieron crear grupos definidos. En el caso del UMAP (**Figura 17.E**) la variable del tipo sexual de la flor (Masculinas o Femeninas) fue más relevante que el estadio de desarrollo (estadio 2, 3 o 4) y se puede comprobar porque los grupos de flores femeninas (FS2, FS3, FS4) y los grupos de flores masculinas (MS2, MS3, MS4) quedan reunidos en lugares muy separados y concentrados de la gráfica. Con el resto de métodos también se crean agrupaciones atendiendo al estadio de desarrollo. Sin embargo, como se puede observar en los gráficos A, B, C y D de la **Figura 17**, las muestras FS4 y MS4 suelen quedar agrupadas y separadas con respecto a las de los estadios 2 y 3 (FS2, FS3, MS2,

MS3). Los resultados obtenidos muestran una distribución coherente con las condiciones experimentales descritas en el estudio original, apoyando la consistencia biológica del conjunto de datos.

Una vez seleccionado el conjunto de datos como ejemplo para el uso del atlas de expresión se buscaron genes relacionados con el desarrollo de la flor y la diferenciación sexual, ya que es el tema tratado en el estudio del cual se obtuvieron los datos. Esta búsqueda se realizó utilizando la propia herramienta de búsqueda de IHSM Subtropicals DB (Tools>Search), además de los genes propuestos en el estudio publicado. Con ello se obtuvo una lista de interés que representa en la **Tabla 6**.

Tabla 6. Tabla con los genes candidatos. Información de los genes extraída de la base de datos de SwissProt y del estudio

Identificador en IHSM Subtropicals	Nombre del gen	Proteína	Descripción
sunup01G0000360.t1	CYC	Transcription factor CYCLOIDEA	Implicado en la asimetría dorsoventral de las flores. Retrasa la tasa de crecimiento y reduce el número de órganos en la región dorsal de las flores.
sunup03G0006420.t1	SUP	Transcriptional regulator SUPERMAN	Probable regulador transcripcional considerado como una proteína cadastral que actúa de forma indirecta para impedir que las proteínas homeóticas de clase B APETALA3 y, posiblemente, PISTILLATA actúen en el verticilo gineceal. Su función principal es equilibrar la proliferación celular en el tercer y cuarto verticilo de las flores en desarrollo, manteniendo así el límite entre los estambres y los carpelos. Puede desempeñar esta función mediante la represión de genes implicados en la división celular. Desempeña igualmente un papel en la determinación del meristemo floral. También es necesaria para el desarrollo normal del óvulo.
sunup01G0020320.t1	HEC2	Transcription factor HEC2	Es necesario para el desarrollo del aparato reproductor femenino y la fertilidad.
sunup03G0020930.t1	MUTE	Transcription factor MUTE	Factor de transcripción. Junto con FMA y SPCH, regula la formación de los estomas. Es necesario para la diferenciación de las células guardianas de los estomas, ya que favorece las sucesivas divisiones celulares asimétricas y la formación de

			células madre guardianas. Favorece la conversión de la epidermis foliar en estomas.
sunup02G0003590.t1	TGA9	Transcription factor TGA9	Desarrollo de la flor
sunup01G0027750.t1	AGL11	Agamous-like MADS-box protein AGL11	Probable factor de transcripción implicado en el desarrollo de la semilla. Desempeña un papel en la morfogénesis de la semilla al favorecer el desarrollo correcto de la capa celular de la endotesta, que dirige el desarrollo posterior del tegumento, el endospermo y, en consecuencia, el embrión.
sunup01G0025300.t1	CYCD3-1	Cyclin-D3-1	Implicado en la vía de biosíntesis de los brasinoesteroides.

Una vez con los genes candidatos seleccionados se puede visualizar cómo se expresan en las distintas condiciones experimentales. El atlas reprodujo perfiles de expresión previamente descritos en literatura.

En la **Figura 18** y **Figura 19** se puede observar un gráfico de barras generado en el atlas de expresión con 6 de estos genes descritos en el estudio como genes con una expresión diferencial entre tipos sexuales.




Figura 18. Representación gráfica de la expresión diferencial de diferentes genes con una mayor expresión en la flor femenina




Figura 19. Representación gráfica de la expresión diferencial de diferentes genes con una mayor expresión en la flor masculina

En la **Figura 18**, se representa expresión en distintas etapas del desarrollo del gen TGA9, implicado en el desarrollo de la flor. Este gen se expresa con mayor intensidad en los primeros estadios y luego decrece. Por otro lado, genes como HEC2 y SUP son más tardíos en el desarrollo. Todos ellos, junto con el CYC, implicado en la asimetría dorsoventral de la flor, se expresan mayoritariamente en flores femeninas, siendo imprescindibles para la diferenciación.

En la **Figura 19** se observa la expresión del gen MUTE, implicado en la diferenciación de las células que luego darán lugar a los estomas. Por ello se expresa únicamente en los primeros estadios del desarrollo. Este gen se expresa con mayor intensidad en flores masculinas.

Todos estos resultados concuerdan con lo presentado en el estudio del cual se obtuvieron los datos.

Este tipo de gráficos además son interactivos ya que se pueden seleccionar los genes específicos que se quieren observar por separado o en conjunto como es el caso de la **Figura 19**.

Otra herramienta de visualización muy útil son las cartas de expresión (**Figura 20**). Con ellas, seleccionando un gen de interés, analizar cómo se expresa dicho gen mostrando además imágenes que ilustran el fenotipo concreto de la muestra. Los colores de las tarjetas representan diferentes rangos de valores de expresión, siendo la tarjeta dorada y la negra los valores más altos y más bajos respectivamente. En este caso se decidió mostrar la expresión del gen AGL11, implicado en el desarrollo de la semilla. Desempeña un papel en la

morfogénesis de la semilla al favorecer el desarrollo correcto de la capa celular de la endotesta, que dirige el desarrollo posterior del tegumento, el endospermo y, en consecuencia, el embrión. Como se puede observar en la **Figura 20**, hay una mayor expresión en las flores femeninas y, en concreto, en los estadios finales (FS4).

Esta representación de tarjetas de expresión permitió interpretar de forma rápida y visual diferencias entre condiciones experimentales, estadios de desarrollo y/o tejidos.




Figura 20. Representación mediante cartas de expresión del gen *AGL11* en distintas muestras

Para ilustrar las siguientes herramientas del atlas se decidió utilizar todos los genes de la **Tabla 6**.

En la **Figura 21** podemos observar un mapa de calor (Heatmap) generado en el atlas. Este tipo de representaciones permite ver de forma conjunta todos los genes y sus valores de expresión en las distintas condiciones experimentales. En él se observó un patrón general de expresión diferencial entre flores femeninas y masculinas en todos los genes seleccionados. También se observaron patrones locales dentro de, por ejemplo, las flores femeninas en las que algunos genes reducían su expresión a lo largo de las diferentes etapas de desarrollo mientras que otros la aumentaban.

Heatmap




Figura 21. Mapa de calor de la expresión diferencial de diferentes genes de interés en distintos estadios de desarrollo de la flor y en distintos tipos sexuales

De igual forma, es de gran utilidad el gráfico de réplicas (**Figura 22**). Aquí se representa de manera individual los valores de expresión de cada gen en cada réplica biológica. En este caso se puede visualizar como algunos valores de expresión de las réplicas son similares entre ellas, llegando incluso a solaparse, mientras que otros tienen valores muy distintos. La similitud mostrada entre réplicas aporta confianza en la consistencia de los datos analizados.

En la **Figura 22** se representan los valores de expresión del gen CYCD3-1, un gen implicado en la vía de biosíntesis de brasinoesteroides, el cual ha sido descrito como uno de los cuales se expresa con mayor intensidad en flores femeninas.




Figura 22. Gráfico de réplicas de la expresión del gen CYCD3-1, en las distintas condiciones experimentales

Por último, el atlas genera una tabla que se puede exportar en los formatos CSV, Excel y PDF (**Figura 23**). Esta tabla muestra la media de los valores de expresión de cada gen, y puede organizarse en varias páginas, además de permitirnos filtrar las columnas o hacer búsquedas dentro de ellas. Además, gracias a los archivos de anotaciones, en esta tabla se pueden enlazar los identificadores propios del atlas (sunup01G0025300.t1) con los identificadores propios de otras bases de datos y sus descripciones (AT4G34160.1: CYCLIN D3;1).

Esto facilita la reutilización de los datos por otros investigadores.

Average values

Copy CSV Excel PDF Print Column visibility Filter by:

Select All Search Gene ID Search FS2 Search FS3 Search FS4 Search MS2 Search MS3 Search MS4 Search Araport11 Search Araport11 Description

Select	Gene ID	FS2	FS3	FS4	MS2	MS3	MS4	Araport11	Araport11 Description
☐	sunup01G0000360.t1	3.95	4.12	6.35	1.35	0.92	0.63	AT1G67260.2	TCP family transcription factor
☐	sunup01G0020320.t1	3.19	13.84	18.06	0.50	0.79	0.28	AT3G50330.1	basic helix-loop-helix (bHLH) DNA-binding superfamily protein
☐	sunup01G0025300.t1	126.84	151.78	183.97	42.84	37.49	28.81	AT4G34160.1	CYCLIN D3;1
☐	sunup01G0027750.t1	44.10	110.82	239.65	0.07	0.07	1.57	AT4G09960.1	K-box region and MADS-box transcription factor family protein
☐	sunup02G0003590.t1	30.96	32.81	9.15	2.02	2.08	0.70	AT1G08320.4	bZIP transcription factor family protein
☐	sunup03G0006420.t1	4.25	11.77	24.59	0.97	0.72	0.37	AT3G23130.1	C2H2 and C2HC zinc fingers superfamily protein
☐	sunup03G0020930.t1	1.72	2.48	2.11	20.01	18.42	0.89	AT3G06120.1	basic helix-loop-helix (bHLH) DNA-binding superfamily protein

Show 25 entries

Showing 1 to 7 of 7 entries

Previous 1 Next

Figura 23. Tabla descargable de los valores medios de expresión de los genes de interés, en distintos estadios de desarrollo de la flor y distintos tipos sexuales

4.3. Archivos de anotaciones

Se generaron archivos de anotaciones con la finalidad enlazar los nombres e identificadores propios de los genes presentes en el atlas con los propios utilizados por otras bases de datos. Esta funcionalidad también se presenta en la tabla mostrada en la **Figura 23**. Esto permitió complementar el atlas de expresión y facilitar la interpretación funcional de los genes identificados.

Los archivos de anotaciones tienen una estructura que se representa en la **Figura 24** de forma abreviada. Se trata de archivos de texto (.txt) en los que las columnas están separadas por tabulaciones y las filas por saltos de línea. Las columnas que podemos distinguir en la **Figura 24** se componen de la siguiente manera:

- **Gene:** correspondiente al identificador de los distintos genes o transcritos de papaya que se encuentran en la base de datos y, por lo tanto, los que se utilizarán en las distintas herramientas como el atlas de expresión.
- **Araport 11:** se trata del identificador que la base de datos de Arapor11 da para el homólogo de ese gen en Arabidopsis.
- **Araport 11 Description:** se trata de la descripción que se puede encontrar en esa base de datos para ese mismo gen. Por ejemplo, para el caso del gen con identificador “AT5G15930.1” su descripción es “plant adhesion molecule 1”.

El resto de columnas siguen la misma dinámica, siendo la primera columna el identificador que una base de datos determinada da a una secuencia que corresponde con un gen; y la segunda columna su descripción. A este respecto se pueden encontrar columnas con los identificadores y descripciones dados por las bases de SwissProt, TrEMBL, NCBI (non-redundant) e InterPro, las cuales tienen características distintas de interés.

Gene	Araport11	Araport11 Description	SwissProt	SwissProt Description	TrEMBL	TrEMBL Description	NCBI
	NR	Description	InterPro	InterPro Description			
sunup01G0000010.t1	AT5G15930.1		plant adhesion molecule 1	Q94BY9	Rab	GTPase-activating protein	22
	A0A2P5BAP1		Rab-GTPase-TBC domain containing protein	XP_021887987.1		EVI5-like protein isoform	X1
[Carica papaya]	IPR000195;IPR035969		Rab-GAP-TBC domain;Rab-GAP-TBC domain superfamily				
sunup01G0000020.t1							
sunup01G0000030.t1	AT3G02450.1		cell division protein ftsH	Q9M895	Probable	inactive ATP-dependent zinc metalloprotease	
	FTSHI 3, chloroplastic	(AtFTSHI3) (Protein FTSH INACTIVE PROTEASE 3)		A0A2H5P1J0		AAA+ ATPase domain-containing protein	
	XP_021903422.1		probable inactive ATP-dependent zinc metalloprotease	FTSHI 3, chloroplastic		[Carica papaya]	
	IPR041569;IPR011546;IPR003959;IPR027417		AAA ATPase, AAA+ lid domain;Peptidase M41, FtsH				
			extracellular;ATPase, AAA-type, core;P-loop containing nucleoside triphosphate hydrolase				
sunup01G0000040.t1	AT5G38710.1		Methylenetetrahydrofolate reductase family protein	Q6NKK1	Proline		
	dehydrogenase 2, mitochondrial	(EC 1.5.5.2) (Osmotic stress-induced proline dehydrogenase) (Proline oxidase)					
	A0A061EI66		Proline dehydrogenase (EC 1.5.5.2)	XP_021903434.1		proline dehydrogenase 2,	
	mitochondrial-like [Carica papaya]		IPR029041;IPR002872			FAD-linked oxidoreductase-like;Proline dehydrogenase domain	
sunup01G0000050.t1	AT5G10730.1		NAD(P)-binding Rossmann-fold superfamily protein				
	A0AAQ3P5Z5		NAD-dependent epimerase/dehydratase domain-containing protein			KAF3962822.1	
			hypothetical protein CMV_012721 [Castanea mollissima]				
sunup01G0000060.t1							
sunup01G0000070.t1	AT3G30841.1		Cofactor-independent phosphoglycerate mutase				
	A0A061F8H4		Cofactor-independent phosphoglycerate mutase	XP_021903411.1		uncharacterized	
	protein LOC110818745 [Carica papaya]		IPR017850;IPR004456;IPR006124			Alkaline-phosphatase-like, core domain	
			superfamily;2,3-bisphosphoglycerate-independent phosphoglycerate mutase;Metalloenzyme				

Figura 24. Ejemplo reducido de archivo de anotaciones

5. Discusión

El presente estudio aborda una necesidad relevante en el estudio genómico de *Carica papaya*: la creación y publicación de un atlas de expresión público con el fin de centralizar y reutilizar de datos públicos de RNA-Seq mediante una herramienta accesible y funcional. Aunque la papaya es un cultivo de alto interés agronómico, nutricional y biotecnológico, la información transcriptómica disponible se encuentra todavía dispersa en repositorios públicos, lo que dificulta su consulta integrada y su aprovechamiento por parte de la comunidad científica. En este contexto, el atlas de expresión desarrollado y puesto a disposición pública en el portal genómico IHSM Subtropicals, permite obtener datos transcriptómicos útiles para la exploración de patrones de expresión génica.

Si bien es cierto que herramientas como este atlas son de uso común para muchos organismos, tanto de plantas como otros seres vivos, existen especies en los que la información transcriptómica es más escasa y se encuentra dispersa en diferentes bases de datos. Este es el caso de *Carica papaya*. La elaboración y presentación de un flujo de trabajo (**Figura 3**) con el que abordar futuros análisis de RNA-Seq en esta y otras especies, facilitará el minado de esta información en bases de datos. Habiendo construido un pipeline eficiente, que ha demostrado ser eficaz en el procesamiento de datos brutos desde bases de datos hasta la incorporación de estos al atlas desarrollado, la ampliación del atlas mediante incorporación de nuevos datasets podrá realizarse de una forma sencilla y sistemática a medida que más grupos de investigación vayan generando nuevos datos transcriptómicos de *Carica papaya*.

La parte del pipeline desarrollado encargada del procesamiento y control de calidad de los datos brutos demostró ser eficiente, lo cual es crucial para la fiabilidad de los análisis posteriores, haciendo más robustos los resultados obtenidos en los procesos de alineamiento, cuantificación e incluso en la generación del propio atlas.

Dentro de la calidad inicial de los datos y el procesamiento de los mismos también se pueden destacar otros aspectos relevantes. Las proporciones de los nucleótidos presentes a lo largo de las lecturas (**Figura 5** y Anexo B) en todos los grupos fue similar. Este patrón repetido en todas las lecturas presente aproximadamente en las 12-15 primeras bases es común en las lecturas de RNA-Seq obtenidas con Illumina. Esto se debe a cómo las bibliotecas de cDNA son preparadas (63). En este proceso, en la síntesis de la primera hebra de cDNA a partir de mRNA,

se utiliza una serie de cebadores, estos, pese a que en teoría deberían estar todos presentes en el mismo tampón de reacción con la misma frecuencia y promover la reacción con la misma eficacia, se ven favorecidos unos frente a otros. Esto provoca el sesgo ya que al haber un favorecimiento de ciertas bases también lo habrá de ciertas lecturas. Esto no se soluciona con el procesado que aplicamos, es decir el de “recortar” las 15 primeras bases, sino que simplemente mueve el punto de inicio de la lectura aguas arriba, pero la proporción de lecturas no varía. Sin embargo y pese a esto, este sesgo no es relevante ya que, como Hansen y su equipo demostraron, ocurre exactamente igual en todas las bibliotecas (63). Es decir que, por ejemplo, las lecturas procedentes de la muestra de papaya sana tienen el mismo sesgo que las procedentes de una papaya con estrés por sequía. La técnica de RNA-Seq consiste en la comparación de unas muestras con otras (Análisis de Expresión Diferencial), por lo tanto, este sesgo se cancela matemáticamente.

Otra parte crucial del procesamiento es la eliminación de los adaptadores y las secuencias sobreexpresadas. La no eliminación de estos puede producir otro tipo de sesgos y que muchas de las secuencias no se alineen bien a la hora de hacer el mapeado. En este sentido FastP demostró su eficacia como se puede observar comparando las **Figuras 6 y 12**, en la que vemos cómo el número de adaptadores prácticamente desaparece; y las **Figuras 8 y 14**, en las que el número de secuencias de polinucleótidos pasa a ser tan pequeño que no aparece en el informe MultiQC.

Otro aspecto importante a tener en cuenta a la hora realizar el procesamiento de las lecturas es el de mantener las proporciones de las lecturas obtenidas. En la **Figura 7** se pudo observar que los niveles correspondientes a las lecturas duplicadas son altas en la mayoría de las muestras. Aunque en el informe MultiQC esto se presenta como un problema, ha de tenerse en cuenta que se trata de lecturas de mRNA, por lo que es esperable que haya lecturas duplicadas debido a la alta expresión de algunos genes cuando se dan ciertas condiciones. Por lo general, estos resultados indican la presencia de transcritos muy abundantes, aunque en menor medida pueden deberse a la acumulación de duplicaciones obtenidas por el propio proceso de amplificación.

La distribución de la longitud de las lecturas cambió únicamente en el BioProject PRJNA565901 (**Figura 13**). Estos cambios en la distribución de las lecturas tras el procesamiento son una

consecuencia de la eliminación de adaptadores y de la aplicación de distintos parámetros de filtrado.

En las siguientes fases del pipeline se vuelve a hacer vigente la importancia de un correcto control de calidad y procesamiento de las lecturas, para que estas puedan proporcionar un buen porcentaje de mapeo sobre el genoma de referencia.

En la **Tabla 5** y el resto de tablas dentro del **Anexo B** se puede observar que el número de lecturas totales presentes en todos los sets de datos es superior a 10 millones de lecturas y no suelen superar los 30 millones de lecturas. Este rango es algo a tener en cuenta a la hora de realizar un buen diseño experimental (64). Sin embargo en los datasets con los BioProject PRJNA470602 y PRJNA565901, el número de replicas biológicas por cada muestras es de tan solo 2, lo cual es considerado insuficiente para un buen diseño (64). Este numero insuficiente puede influir de manera negativa en la robustez de los datos presentados en el propio estudio del BioProject y, por consiguiente, en el atlas generado. Esto se debe a que puede que las diferencias de expresión mostradas en los datos finales se deban a sesgos generados por el escaso número de réplicas, y no porque las diferentes condiciones experimentales influyan de esa manera en la realidad. Por este motivo es conveniente elegir estudios donde el numero de replicas biológicas sea por lo menos de 3, que es el mínimo consensuado.

En el procesamiento de los datos con el pipeline se pudo comprobar cómo las lecturas pertenecientes al BioProject PRJNA880626 mostraban valores correspondientes con contaminación con otras especies. Pese a la labor de descontaminación, estos valores no disminuyeron y se decidió continuar con el flujo de trabajo atendiendo al porcentaje de lecturas mapeadas para así finalmente descartar o no este conjunto de datos. Los valores mínimos generados en algunas de las lecturas fueron del 73,81%, lo cual muestra que el impacto de la contaminación fue poco relevante. Esta bajada del porcentaje comparado con otros datasets (**Tabla 5**), se debió a la presencia de un porcentaje de lecturas no pertenecientes a *Carica papaya* y que, por lo tanto, a la hora de ser mapeadas, no pudieron ser localizadas en el genoma de referencia. Tratándose de experimentos de RNA-Seq, este porcentaje de 73,81% entró dentro del rango que se consideró aceptable.

Una vez finalizado todo el proceso del pipeline y habiendo construido el atlas, este se puso a prueba mediante un ejemplo práctico utilizando como dataset de testeo al perteneciente al BioProject PRJNA687615, el cual pertenece a un estudio de análisis de expresión diferencial

entre flores masculinas y femeninas de papaya en diferentes estadios de desarrollo. Se decidió utilizar este estudio ya que aportaba un ejemplo con una gran cantidad de condiciones experimentales distintas, fácilmente reconocibles, con gran cantidad de información al respecto de los genes candidatos y con gran cantidad de imágenes muy ilustrativas.

Empleando el atlas de expresión en la caracterización de genes expresados diferencialmente entre flores femeninas y masculinas, se pudo observar la utilidad de esta herramienta. Se comprobó que genes descritos con funciones relativas a la floración, o con expresión diferencial por tipos sexuales, también generaban gráficas que mostraban esta diferencia de expresión. Las **Figuras 18, 19, 20, 21 y 22** permitieron la visualización, mediante diferentes tipos de gráficas, que genes como CYC, SUP, HEC2, TGA9, AGL11 y CYCD3-1 tienen una mayor presencia en flores femeninas. Dentro de los genes implicados directamente con la floración, TGA9 muestra una disminución en la expresión a lo largo del desarrollo de la flor, mientras que CYC, SUP y HEC2, que son genes de expresión más tardía, muestran un aumento. También se pudo observar de forma gráfica la expresión diferencial del gen MUTE, que es mayoritariamente en flores masculinas. Esto concuerda con los resultados publicados por los estudios de donde se obtuvo los genes candidatos (58). Además, los resultados obtenidos en la realización de diferentes análisis de reducción de la dimensionalidad respaldan el buen diseño experimental de este estudio (**Figura 17**).

El hecho de que los resultados mostrados usando el atlas de expresión concuerden con los datos mostrados en el artículo publicado del cual se extrajeron, es otra forma de corroborar la robustez de este estudio. Pero también es una forma de demostrar la utilidad del atlas ya que, en posibles trabajos futuros, en los que un grupo de investigación quiera realizar una búsqueda “in silico” de posibles genes candidatos de papaya expresados diferencialmente en flores masculinas y femeninas, este atlas puede ser una herramienta muy potente y un primer paso para el desarrollo de esa línea de investigación. Además, al tratarse de un atlas que toma información de un conjunto de 8 datasets distintos (**Tabla 4**), cada uno perteneciente a un estudio que abarca diferentes tejidos y condiciones experimentales, la información no se limita solamente a la expresión diferencial en diferentes tipos sexuales de papaya, sino que existe un amplio catálogo de condiciones concretas a estudiar. Y, como apunte final, este catálogo podrá ser ampliado a medida que nueva información transcriptómica surja fruto de nuevos experimentos, ya que se podrá usar el pipeline desarrollado para incluirla en el atlas.

Un aspecto a tener en cuenta a la hora de construir el atlas de expresión fue el de intentar reducir al mínimo el llamado “Batch effect”, el cual se produce cuando las diferencias de expresión entre muestras se deben a causas metodológicas o técnicas y no biológicas. Por ejemplo, diferencias debidas a la toma de muestras en tiempos y condiciones muy distintas, con métodos de extracción de RNA diferentes y hechos por distintos grupos de investigación. Intentando minimizar este tipo de sesgos el atlas está estructurado de tal forma que solo se pueden visualizar los datos de expresión relativos a un único dataset, pertenecientes a un único Bioproject. De esta manera, se reduce la variabilidad relativa a las diferencias entre experimentos. Dentro de cada experimento, a su vez, se realizaron pruebas de calidad como la mostrada en el ejemplo práctico, con la intención de medir la calidad del diseño experimental (**Figura 17**). Teniendo esto en cuenta también se podría plantear un futuro en el que todos estos dataset estuvieran presentes para ser visualizados a la vez, pero esto conllevaría una labor previa de normalización y eliminación del todo este “ruido” producido por el Batch effect, lo cual puede ser enormemente complejo y excede las capacidades de este trabajo fin de master. Aun así se pueden mencionar métodos de corrección del Batch effect como ComBat que podrían permitir integrar todos los conjuntos de datos en una posible línea de desarrollo futura (65).

Uno de los mayores problemas al que se enfrenta el estudio biológico de plantas es la poca organización, centralización y facilidad de obtención de datos genómicos de ciertas especies, incluso cuando estas son de gran interés agronómico, como es el caso de la papaya. Por lo tanto, la creación de portales genómicos especializados que dispongan de herramientas útiles para la investigación es uno de los pasos más importantes a dar a este respecto, ya que sienta una base sólida sobre la que otros grupos de investigación más aplicados pueden trabajar. También es útil para la industria agronómica que se puede servir tanto de esta fuente de datos bruta como de las investigaciones derivadas de ella. Otros atlas desarrollados en este mismo grupo de investigación sobre la base de EasyGDB ([OliveAtlas](#)) (41), ya están siendo utilizados por otras instituciones como la Estación Experimental del Zaidín (EEZ) para la búsqueda *in silico* de genes candidatos en olivo. Esto demuestra, otra vez, la utilidad de estas herramientas.

Por último, cabe destacar las cualidades concretas de este atlas, que ofrece una amplia variedad de herramientas de visualización para explorar y comparar los datos de expresión en diversos tejidos y condiciones experimentales. Las gráficas generadas son interactivas, lo que

permite seleccionar genes específicos por separado, ampliar las imágenes y guardar las figuras y tablas en diferentes formatos. Todo esto puede permitir a los investigadores buscar y seleccionar buenos genes candidatos para un estudio, fortaleciendo así su diseño experimental.

Este es uno de los primeros atlas de papaya publicado y de acceso público que se conoce hasta la fecha, por lo que su importancia puede ser crucial para el diseño de futuros estudios que pretendan encontrar genes candidatos para, por ejemplo, resistencia a enfermedades víricas o a estrés por sequía. Con ello no solo se favorece a la comunidad científica sino también al desarrollo de otras entidades agrícolas.

6. Conclusiones

- Se diseñó un pipeline reproducible para el flujo de trabajo de RNA-Seq que ha permitido y permitirá seguir ampliando la información transcriptómica disponible en el atlas de expresión generado.
- Los datasets seleccionados mostraron una calidad adecuada para su correcta integración en la plataforma.
- Se desarrolló e integró con éxito un atlas público de expresión de *Carica papaya* en el portal IHSM Subtropicals, proporcionando un recurso organizado y reutilizable para la comunidad científica.
- La herramienta demostró su utilidad práctica en la caracterización de los mecanismos de desarrollo de las flores masculinas y femeninas en papaya. Demostrando su valor útil en futuros proyectos que tuvieran como objetivo encontrar genes candidatos *in silico*.
- La disponibilidad de este recurso proporcionó información valiosa acerca de cómo los genes se expresan en esta especie, lo cual facilita la interpretación de los resultados y la toma de decisiones en los experimentos.
- Finalmente, la accesibilidad pública del atlas de expresión fomentará la colaboración científica y permitirá mejoras genéticas y agronómicas en papaya.

Referencias bibliográficas

1. Atmaca S, Yolcu Hİ, Erdoğan G, Gübbük H, Sert H. Comparison of the morphological characteristics, yield, and quality traits of fruits of two papaya cultivars grown under protected cultivation. *Horticulturae*. 2024;10(11).
2. Koul B, Pudhuvai B, Sharma C, Kumar A, Sharma V, Yadav D, et al. *Carica papaya* L.: a tropical fruit with benefits beyond the tropics. *Diversity*. 2022;14(8):683. doi:10.3390/d14080683.
3. Urasaki N, Tokumoto M, Tarora K, Ban Y, Kayano T, Tanaka H, et al. A male and hermaphrodite specific RAPD marker for papaya (*Carica papaya* L.). *Theor Appl Genet*. 2002;104(2-3):281-285. doi:10.1007/s001220100693.
4. Pereira Duarte R, Cancela Ramos HC, Rodrigues Xavier L, Azevedo Vimercati Pirovani A, Souza Rodrigues A, Turquetti-Moraes DK, et al. Comparative proteomic analysis of papaya bud flowers reveals metabolic signatures and pathways driving hermaphrodite development. *Sci Rep*. 2024;14(1):1-17. doi:10.1038/s41598-024-59306-x.
5. Food and Agriculture Organization of the United Nations. Major tropical fruits market review: preliminary results 2022. Rome: FAO; 2023.
6. Karunamoorthi K, Kim HM, Jegajeevanram K, Xavier J, Vijayalakshmi J. Papaya: a gifted nutraceutical plant - a critical review of recent human health research. *Tang [Humanitas Med]*. 2014;4(1):2.1-2.17. doi:10.5667/tang.2013.0028.
7. Saeed F, Arshad MU, Pasha I, Naz R, Batool R, Khan AA, et al. Nutritional and phyto-therapeutic potential of papaya (*Carica papaya* Linn.): an overview. *Int J Food Prop*. 2014;17(7):1637-1653. doi:10.1080/10942912.2012.709210.
8. de Oliveira JG, Vitória AP. Papaya: nutritional and pharmacological characterization, and quality loss due to physiological disorders. An overview. *Food Res Int*. 2011;44(5):1306-1313.
9. Aruoma OI, Colognato R, Fontana I, Gartlon J, Migliore L, Koike K, et al. Molecular effects of fermented papaya preparation on oxidative damage, MAP kinase activation and modulation of the benzo[a]pyrene mediated genotoxicity. *BioFactors*. 2006;26(2):147-159.

10. Mehdipour S, Yasa N, Dehghan G, Khorasani R, Mohammadirad A, Rahimi R, et al. Antioxidant potentials of Iranian *Carica papaya* juice in vitro and in vivo are comparable to α -tocopherol. *Phytother Res.* 2006;20(7):591-594.
11. Starley IF, Mohammed P, Schneider G, Bickler SW. The treatment of paediatric burns using topical papaya. *Burns.* 1999;25(7):636-639.
12. Vijaykumar H, Pai SA, Pandey V, Kamble P. Comparative study of collagenase and papain-urea based preparations in the management of chronic nonhealing limb ulcers. *Indian J Sci Technol.* 2011;4(9):1090-1100.
13. Osato JA, Santiago LA, Remo GM, Cuadra MS, Mori A. Antimicrobial and antioxidant activities of unripe papaya. *Life Sci.* 1993;53(17):1383-1389.
14. Ayoola PB, Adeyeye A, State O. Phytochemical and nutrient evaluation of *Carica papaya* (pawpaw) leaves. 2010;5(December):325-328.
15. Arumuganathan K, Earle ED. Nuclear DNA content of some important plant species. *Plant Mol Biol Rep.* 1991;9(3):208-218.
16. Storey WB. Outlines of perennial crop breeding in the tropics. In: F. WIT Foundation for Agricultural Plant Breeding, editor. Wageningen: Veenman; 1969. p. 389-408.
17. Ming R, Yu Q, Moore PH. Sex determination in papaya. *Semin Cell Dev Biol.* 2007;18(3):401-408.
18. Zerpa-Catanho D, Wai J, Wang ML, Yu L, Nguyen J, Ming R. Differential gene expression among three sex types reveals a MALE STERILITY 1 (CpMS1) for sex differentiation in papaya. *BMC Plant Biol.* 2019;19(1):1-22. doi:10.1186/s12870-019-2169-0.
19. Tennant PF, Fermin GA, Roye ME. Viruses infecting papaya (*Carica papaya* L.): etiology, pathogenesis, and molecular biology. *Plant Viruses.* 2007;1(2):178-188.
20. Tripathi S, Bau HJ, Chen LF, Yeh SD. The ability of Papaya ringspot virus strains overcoming the transgenic resistance of papaya conferred by the coat protein gene is not correlated with higher degrees of sequence divergence from the transgene. *Eur J Plant Pathol.* 2004;110(9):871-882.
21. Gonsalves D. Control of papaya ringspot virus in papaya: a case study. *Annu Rev Phytopathol.* 1998;36:415-437.

22. Fitch MMM, Manshardt RM, Gonsalves D, Slightom JL, Sanford JC. Virus resistant papaya plants derived from tissues bombarded with the coat protein gene of papaya ringspot virus. *Nat Biotechnol.* 1992;10(11):1466-1472.
23. Fitch MMM, Manshardt RM, Gonsalves D, Slightom JL, Sanford JC. Stable transformation of papaya via microprojectile bombardment. *Plant Cell Rep.* 1990;9(4):189-194.
24. Yue J, VanBuren R, Liu J, Fang J, Zhang X, Liao Z, et al. SunUp and Sunset genomes revealed impact of particle bombardment mediated transformation and domestication history in papaya. *Nat Genet.* 2022;54(5):715-724.
25. Mortazavi A, Williams BA, McCue K, Schaeffer L, Wold B. Mapping and quantifying mammalian transcriptomes by RNA-Seq. *Nat Methods.* 2008;5(7):621-628.
26. Li B, Dewey CN. RSEM: accurate transcript quantification from RNA-Seq data with or without a reference genome. *BMC Bioinformatics.* 2011;12:323.
27. Bolger AM, Lohse M, Usadel B. Trimmomatic: a flexible trimmer for Illumina sequence data. *Bioinformatics.* 2014;30(15):2114-2120.
28. Chen S, Zhou Y, Chen Y, Gu J. Fastp: an ultra-fast all-in-one FASTQ preprocessor. *Bioinformatics.* 2018;34(17):i884-i890.
29. Falgueras J, Lara AJ, Fernández-Pozo N, Cantón FR, Pérez-Trabado G, Claros MG. SeqTrim: a high-throughput pipeline for pre-processing any type of sequence read. *BMC Bioinformatics.* 2010;11:38.
30. Martin M. Cutadapt removes adapter sequences from high-throughput sequencing reads. *EMBnet.journal.* 2011;17(1):10-12.
31. Kim D, Paggi JM, Park C, Bennett C, Salzberg SL. Graph-based genome alignment and genotyping with HISAT2 and HISAT-genotype. *Nat Biotechnol.* 2019;37(8):907-915.
32. Wu TD, Nacu S. Fast and SNP-tolerant detection of complex variants and splicing in short reads. *Bioinformatics.* 2010;26(7):873-881.
33. Dobin A, Davis CA, Schlesinger F, Drenkow J, Zaleski C, Jha S, et al. STAR: ultrafast universal RNA-seq aligner. *Bioinformatics.* 2013;29(1):15-21.

34. Love MI, Huber W, Anders S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biol.* 2014;15(12):550.
35. Robinson MD, McCarthy DJ, Smyth GK. edgeR: a Bioconductor package for differential expression analysis of digital gene expression data. *Bioinformatics.* 2010;26(1):139-140.
36. Ritchie ME, Phipson B, Wu D, Hu Y, Law CW, Shi W, et al. limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Res.* 2015;43(7):e47.
37. The Galaxy Community. The Galaxy platform for accessible, reproducible and collaborative biomedical analyses: 2022 update. *Nucleic Acids Res.* 2022;50(W1):W345-W351.
38. Phytozome [Internet]. [cited 2026 Apr 23]. Available from: <https://phytozome-next.jgi.doe.gov/>
39. MangoBase [Internet]. [cited 2026 Apr 23]. Available from: https://mangobase.org/easy_gdb/index.php
40. Fernandez-Pozo N, Bombarely A. EasyGDB: a low-maintenance and highly customizable system to develop genomics portals. *Bioinformatics.* 2022;38(16):4048-4050.
41. Bullones A, Castro AJ, Lima-Cabello E, Alché JD, Luque F, Claros MG, et al. OliveAtlas: a gene expression atlas tool for *Olea europaea*. *Plants.* 2023;12(6):1274.
42. Gómez-Ollé A, Bullones A, Hormaza JI, Mueller LA, Fernandez-Pozo N. MangoBase: a genomics portal and gene expression atlas for *Mangifera indica*. *Plants.* 2023;12(6):1273.
43. Sanchez-Vera V, Lopez-Gomez E, Metz G, Haas FB, Silva-Reiriz F, Hiltemann S, et al. MAdLandExpression: integrating sexual reproduction into the *Physcomitrium patens* expression atlas. *Plant J.* 2026;125(2):e70661.
44. Cock PJA, Fields CJ, Goto N, Heuer ML, Rice PM. The Sanger FASTQ file format for sequences with quality scores, and the Solexa/Illumina FASTQ variants. *Nucleic Acids Res.* 2010;38(6):1767-1771.

45. Andrews S. FastQC: a quality control tool for high throughput sequence data [Internet]. Babraham Bioinformatics; 2010 [cited 2026 Feb 6]. Available from: <https://www.bioinformatics.babraham.ac.uk/projects/fastqc/>
46. Ewels P, Magnusson M, Lundin S, Käller M. MultiQC: summarize analysis results for multiple tools and samples in a single report. *Bioinformatics*. 2016;32(19):3047-3048.
47. Ferragina P, Manzini G. Opportunistic data structures with applications. In: *Proc. Annu Symp Found Comput Sci*. 2000. p. 390-398.
48. Burrows M, Wheeler DJ. A block-sorting lossless data compression algorithm. *SRC Res Rep*. 1994.
49. Li H, Handsaker B, Wysoker A, Fennell T, Ruan J, Homer N, et al. The Sequence Alignment/Map format and SAMtools. *Bioinformatics*. 2009;25(16):2078-2079.
50. Liao Y, Smyth GK, Shi W. FeatureCounts: an efficient general purpose program for assigning sequence reads to genomic features. *Bioinformatics*. 2014;30(7):923-930.
51. R Core Team. R: the R project for statistical computing [Internet]. Vienna, Austria: R Foundation for Statistical Computing; 2024 [cited 2026 Feb 10]. Available from: <https://www.r-project.org/>
52. Thompson J, Brett C, Neuhaus I, Thompson R. DGEobj.utils: differential gene expression (DGE) analysis utility toolkit [Internet]. CRAN; 2021 Apr 28 [cited 2026 Feb 10]. Available from: <https://cran.r-project.org/package=DGEobj.utils>
53. Merkel D. Docker: lightweight Linux containers for consistent development and deployment [Internet]. 2014 [cited 2026 Feb 10]. Available from: <http://www.docker.io>
54. Buchfink B, Reuter K, Drost HG. Sensitive protein alignments at tree-of-life scale using DIAMOND. *Nat Methods*. 2021;18(4):366-368.
55. Jones P, Binns D, Chang HY, Fraser M, Li W, McAnulla C, et al. InterProScan 5: genome-scale protein function classification. *Bioinformatics*. 2014;30(9):1236-1240.
56. Soares CG, Do Prado SBR, Andrade SCS, Fabi JP. Systems biology applied to the study of papaya fruit ripening: the influence of ethylene on pulp softening. *Cells*. 2021;10(9):1-19.

57. Zhou Z, Kanchana-udomkan C, Ford R, Bar I. Identification and validation of key genes related to preferred flavour profiles in Australian commercial papaya (*Carica papaya* L.). *Int J Mol Sci.* 2024;25(5).
58. Liao Z, Dong F, Liu J, Xu L, Marshall-Colon A, Ming R. Gene regulation network analyses of pistil development in papaya. *BMC Genomics.* 2022;23(1):1-14. doi:10.1186/s12864-021-08197-7.
59. Zhou P, Fatima M, Ma X, Liu J, Ming R. Auxin regulation involved in gynoecium morphogenesis of papaya flowers. *Hortic Res.* 2019;6(1). doi:10.1038/s41438-019-0205-8.
60. Zhao X, Song J, Zeng Q, Ma Y, Fang H, Yang L, et al. Auxin and cytokinin mediated regulation involved in vitro organogenesis of papaya. *J Plant Physiol.* 2021;260:153405.
61. Gamboa-Tuz SD, Pereira-Santana A, Zamora-Briseño JA, Castano E, Espadas-Gil F, Ayala-Sumuano JT, et al. Transcriptomics and co-expression networks reveal tissue-specific responses and regulatory hubs under mild and severe drought in papaya (*Carica papaya* L.). *Sci Rep.* 2018;8(1):1-16.
62. An N, Lv J, Zhang A, Xiao C, Zhang R, Chen P. Gene expression profiling of papaya (*Carica papaya* L.) immune response induced by CTS-N after inoculating PLDMV. *Gene.* 2020;755:144852.
63. Hansen KD, Brenner SE, Dudoit S. Biases in Illumina transcriptome sequencing caused by random hexamer priming. *Nucleic Acids Res.* 2010;38(12):e131.
64. Liu Y, Zhou J, White KP. RNA-seq differential expression studies: more sequence or more replication? *Bioinformatics.* 2014;30(3):301-304.
65. ComBat: adjust for batch effects using an empirical Bayes framework in sva: Surrogate Variable Analysis [Internet]. [cited 2026 Jul 6]. Available from: <https://rdrr.io/bioc/sva/man/ComBat.html>

ANEXO A. Scripts

A.1. *ENA_file_download.sh*

```
#!/usr/bin/env bash

wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/003/SRR7145713/SRR7145713_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/007/SRR7145707/SRR7145707_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/006/SRR7145706/SRR7145706_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/005/SRR7145705/SRR7145705_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/001/SRR7145711/SRR7145711_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/005/SRR7145715/SRR7145715_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/002/SRR7145712/SRR7145712_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/004/SRR7145714/SRR7145714_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/008/SRR7145708/SRR7145708_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/009/SRR7145709/SRR7145709_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/008/SRR7145708/SRR7145708_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/003/SRR7145703/SRR7145703_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/007/SRR7145707/SRR7145707_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/009/SRR7145709/SRR7145709_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/000/SRR7145710/SRR7145710_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/004/SRR7145704/SRR7145704_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/000/SRR7145700/SRR7145700_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/002/SRR7145702/SRR7145702_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/001/SRR7145701/SRR7145701_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/004/SRR7145704/SRR7145704_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/005/SRR7145715/SRR7145715_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/009/SRR7145699/SRR7145699_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/006/SRR7145706/SRR7145706_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/002/SRR7145702/SRR7145702_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/004/SRR7145714/SRR7145714_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/003/SRR7145703/SRR7145703_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/005/SRR7145705/SRR7145705_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/006/SRR7145716/SRR7145716_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/000/SRR7145700/SRR7145700_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/001/SRR7145711/SRR7145711_1.fastq.gz
```

```
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/009/SRR7145699/SRR7145699_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/006/SRR7145716/SRR7145716_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/002/SRR7145712/SRR7145712_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/003/SRR7145713/SRR7145713_1.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/001/SRR7145701/SRR7145701_2.fastq.gz
wget -nc ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR714/000/SRR7145710/SRR7145710_1.fastq.gz
```

A.2. Tabla de metadatos

```
from Bio import Entrez
import pandas as pd
import xml.etree.ElementTree as ET
import time

Entrez.email = "alexph_lau@proton.me"

def get_full_atlas_metadata(project_id):
    print(f"--- Procesando {project_id} ---")

    # 1. Obtener IDs de SRA vinculados al BioProject
    # Usamos esearch en 'sra' directamente con el project_id
    search_handle = Entrez.esearch(db="sra", term=project_id, retmax=500)
    search_results = Entrez.read(search_handle)
    search_handle.close()

    id_list = search_results["IdList"]
    if not id_list:
        return f"No se encontraron datos SRA para {project_id}"

    # 2. Fetch de los resultados de SRA (contiene Info técnica + BioSample)
    fetch_handle = Entrez.efetch(db="sra", id=",".join(id_list),
rettype="full", retmode="xml")
    sra_data = fetch_handle.read()
    fetch_handle.close()
```

```
root = ET.fromstring(sra_data)
all_records = []

# Corregido: 'experiment' como una sola palabra
for experiment in root.findall('EXPERIMENT_PACKAGE'):
    # Extraer información de la corrida (Run)
    run = experiment.find("./RUN")
    if run is None: continue # Saltar si no hay datos de run
    run_accession = run.attrib['accession']

    # Extraer Layout
    layout_node = experiment.find("./LIBRARY_LAYOUT/*")
    library_layout = layout_node.tag if layout_node is not None else
"UNKNOWN"

    # Extraer Info de Muestra
    sample_node = experiment.find("./SAMPLE")
    biosample_id = sample_node.attrib['accession'] if sample_node is not
None else "N/A"

    row = {
        "BioProject": project_id,
        "Run": run_accession,
        "BioSample": biosample_id,
        "Library_Layout": library_layout
    }

    # Extraer atributos dinámicos (Treatment, Tissue, etc.)
    for attr in experiment.findall("./SAMPLE_ATTRIBUTE"):
        tag_node = attr.find("TAG")
        val_node = attr.find("VALUE")
        if tag_node is not None and val_node is not None:
            tag = tag_node.text.lower().replace(" ", "_")
            row[tag] = val_node.text
```

```
all_records.append(row)

return pd.DataFrame(all_records)

# Lista de tus BioProjects para el TFM
projects = ["PRJNA470602", "PRJNA591254", "PRJNA687615", "PRJNA549650",
"PRJNA713527", "PRJNA565901", "PRJNA880626", "PRJNA528193"]

# Ejecutar y concatenar todo en un solo dataframe maestro
final_df = pd.concat([get_full_atlas_metadata(p) for p in projects],
ignore_index=True)

# Guardar el "Master Metadata" para tu TFM
final_df.to_csv("master_metadata_atlas_papaya.csv", index=False)
print("Análisis de metadatos completado.")
```

A.3. Creación entorno

```
# Para crear el entorno
mamba create -n tfm_papaya fastqc fastp hisat2 subread samtools multiqc -c
bioconda

# Para activar el entorno
eval "$(mamba shell hook --shell bash)"
mamba activate tfm_papaya

# Para desactivar el entorno
mamba deactivate
```

A.4. FastQC

```
#!/bin/bash
eval "$(mamba shell hook --shell bash)"

mamba activate tfm_papaya

CPUS=8 # preguntar por el número de CPUs a usar
```

```
INPUT_DIR="../../03_trimmed_data_fastp/PRJNA713527" # la ruta de los archivos
fastq

OUTPUT_DIR="../../04_qc_final_fastp/PRJNA713527"

mkdir -p "$OUTPUT_DIR" #esto es por si no existe ya el directorio de salida

fastqc "$INPUT_DIR"/*.fastq.gz -o "$OUTPUT_DIR" -t $CPUS #mirar bien si la
extension es .fq o fastq

multiqc "$OUTPUT_DIR" --interactive -o "$OUTPUT_DIR"

mamba deactivate
```

A.5. Buid SILVA_DB kraken

```
#!/usr/bin/env bash
#SBATCH -J build-kraken2-silva
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=32
#SBATCH --mem=64gb
#SBATCH --time=1-00:00:00
#SBATCH --constraint=cal
#SBATCH --error=build_silva.%J.err
#SBATCH --output=build_silva.%J.out

module purge
module load kraken/2.1.5

SILVA_DB=/mnt2/fscratch/users/ihs_m_fruti_uma/alexph/04_silva

# Añadir los ficheros SILVA descargados previamente a la librería
kraken2-build --add-to-library
$SILVA_DB/SILVA_138.2_SSURef_NR99_tax_silva.fasta.gz --db $SILVA_DB
kraken2-build --add-to-library
$SILVA_DB/SILVA_138.2_LSURef_NR99_tax_silva.fasta.gz --db $SILVA_DB

# Descargar solo la taxonomía (sí necesita internet, pero es muy ligera)
# Si tampoco funciona, pide a los administradores la taxonomía de NCBI
kraken2-build --download-taxonomy --db $SILVA_DB

# Construir la DB con los ficheros locales
time kraken2-build --build \
  --db $SILVA_DB \
  --threads $SLURM_CPUS_PER_TASK
```

A.6. Kraken classify


```
#!/usr/bin/env bash
# Leave only one comment symbol on selected options
# Those with two comments will be ignored:

# The name to show in queue lists for this job:
#SBATCH -J kraken2-silva-rnaseq

# Number of desired cpus (can be in any node):
#SBATCH --ntasks=1

# Number of desired cpus (all in same node):
#SBATCH --cpus-per-task=128

# Amount of RAM needed for this job:
# La DB de SILVA para Kraken2 es mucho más ligera que NR (~8 GB)
#SBATCH --mem=32gb

# The time the job will be running:
#SBATCH --time=7-00:00:00

# To use GPUs you have to request them:
##SBATCH --gres=gpu:1

# Nodos disponibles en Picasso:
#   AMD: 128 cores / 1800GB RAM | AMD: 128 cores / 439GB RAM | Intel: 52
cores / 187GB RAM
# "cal" asigna cualquier nodo que satisfaga tus requisitos (recomendado por
defecto)
#SBATCH --constraint=cal
##SBATCH --constraint=amd
##SBATCH --constraint=intel

# Set output and error files
#SBATCH --error=kraken2_silva.%J.err
#SBATCH --output=kraken2_silva.%J.out

##SBATCH --array=0-63

module purge
module load kraken/2.1.5

#

# PASO 0 – CONSTRUIR LA BASE DE DATOS DE SILVA (solo la primera vez)
#
# Ejecuta esto en un nodo interactivo ANTES de lanzar este job:
#
# kraken2-build --special silva --db
/mnt2/fscratch/users/ihs_m_fruti_uma/alexph/04_silva --threads 32
```

```
#
# El comando descarga automáticamente SILVA 138.2 y construye la DB.
# Tarda unas horas; ejecútalo de forma INTERACTIVA antes de lanzar este job.
# Si tu clúster ya dispone de una DB de Kraken2+SILVA, consulta la ruta
# con los administradores y úsala directamente en SILVA_DB.
#

# — Rutas

SILVA_DB=/mnt2/fscratch/users/ihsm_fruti_uma/alexph/04_silva
DATA_DIR=../01_raw_data/PRJNA880626
OUTDIR=$DATA_DIR/kraken2_out

mkdir -p $OUTDIR

for FILE_R1 in ${DATA_DIR}/*_1.fastq.gz
do
    [ -e "$FILE_R1" ] || continue
    FILENAME=$(basename "$FILE_R1")
    SAMPLE_NAME=${FILENAME%_1.fastq.gz}
    FILE_R2="${FILE_R1/1.fastq.gz/2.fastq.gz}"

    echo ">>> Procesando muestra: $SAMPLE_NAME"
    echo "    R1: $FILE_R1"
    echo "    R2: $FILE_R2"

    time kraken2 \
        --db $SILVA_DB \
        --threads $SLURM_CPUS_PER_TASK \
        --paired \
        --classified-out $OUTDIR/${SAMPLE_NAME}_rRNA#.fastq \
        --unclassified-out $OUTDIR/${SAMPLE_NAME}_clean#.fastq \
        --output $OUTDIR/${SAMPLE_NAME}_output.tsv \
        --report $OUTDIR/${SAMPLE_NAME}_report.txt \
        --confidence 0.05 \
        $FILE_R1 $FILE_R2
done
```

A.7. FastP

```
#!/bin/bash

eval "$(mamba shell hook --shell bash)"

mamba activate tfm_papaya

CPUS=8 # preguntar por el número de CPUs a usar
INPUT_DIR="../../01_raw_data/PRJNA591254" # la ruta de los archivos fastq
OUTPUT_DIR="../../03_trimmed_data/PRJNA591254" # la ruta donde se guardarán los
archivos recortados

mkdir -p "$OUTPUT_DIR" #esto es por si no existe ya el directorio de salida

echo "Iniciando FastP..."
echo "El directorio de entrada: $INPUT_DIR"

for FILE_1 in "$INPUT_DIR"/*.fastq.gz; do

    if [[ "$FILE_1" == *"_2.fastq.gz"* ]] || [[ "$FILE_1" == *"_2"* ]]; then
        continue
    fi

    BASENAME=$(basename "$FILE_1")

    FILE_2="${FILE_1/_1.fastq/_2.fastq}"
    if [ ! -f "$FILE_2" ]; then
        FILE_2="${FILE_1/_1/_2}"
    fi

    if [ -f "$FILE_2" ] && [ "$FILE_2" != "$FILE_1" ]; then
```

```
echo ">>> Procesando PE: $BASENAME"

SAMPLE_NAME=${BASENAME/_1.fastq.gz/}
SAMPLE_NAME=${SAMPLE_NAME/_1.fastq.gz/}

OUT_1="$OUTPUT_DIR/${SAMPLE_NAME}_1_clean.fastq.gz"
OUT_2="$OUTPUT_DIR/${SAMPLE_NAME}_2_clean.fastq.gz"
HTML="$OUTPUT_DIR/${SAMPLE_NAME}_fastp.html"
JSON="$OUTPUT_DIR/${SAMPLE_NAME}_fastp.json"

    fastp --in1 $FILE_1 --in2 $FILE_2 --out1 $OUT_1 --out2 $OUT_2 -h
"$HTML" -j "$JSON" --trim_front1 15 --trim_front2 15 --length_required 36 --
detect_adapter_for_pe --cut_front --cut_front_window_size 1 --
cut_front_mean_quality 3 --cut_right --cut_right_window_size 4 --
cut_right_mean_quality 15 --thread $CPUS --trim_poly_x

else

echo ">>> Procesando SE: $BASENAME"

SAMPLE_NAME=${BASENAME/.fastq.gz/}
OUT_1="$OUTPUT_DIR/${SAMPLE_NAME}_clean.fastq.gz"
HTML="$OUTPUT_DIR/${SAMPLE_NAME}_fastp.html"
JSON="$OUTPUT_DIR/${SAMPLE_NAME}_fastp.json"

    fastp --in1 $FILE_1 --out1 $OUT_1 -h "$HTML" -j "$JSON" --
trim_front1 15 --trim_front2 15 --length_required 36 --cut_front --
cut_front_window_size 1 --cut_front_mean_quality 3 --cut_right --
cut_right_window_size 4 --cut_right_mean_quality 15 --thread $CPUS --
trim_poly_x --phred64

fi

done

echo "Proceso terminado"

mamba deactivate
```

A.8. HISAT2 paired ends

```
#!/bin/bash

eval "$(mamba shell hook --shell bash)"
mamba activate tfm_papaya

CPUS=10
INPUT_DIR="../../03_trimmed_data/PRJNA591254"
OUTPUT_DIR="../../05_alignment/PRJNA591254"

GENOME_FASTA="../../07_genome/GWHBFSC000000000.genome.fasta"
INDEX_DIR="../../07_genome/index_hisat2"
INDEX_PREFIX="${INDEX_DIR}/papaya_ref"

ERR_FILE="$OUTPUT_DIR/hisat2.err"
OUT_FILE="$OUTPUT_DIR/hisat2.out"

mkdir -p "$INDEX_DIR"

# esto es para crear el indice, si ya existe se lo salta
if [ -f "${INDEX_PREFIX}.1.ht2" ]; then
    echo ">>> AVISO: El índice ya existe en $INDEX_DIR."
    echo ">>> Saltando paso de construcción para ahorrar tiempo."
else
    echo ">>> El índice no existe. Construyendo ahora..."
    echo ">>> Genoma entrada: $GENOME_FASTA"

    if [ -f "$GENOME_FASTA" ]; then

        hisat2-build -p $CPUS $GENOME_FASTA $INDEX_PREFIX
        echo ">>> ¡Índice construido con éxito!"
    else
        echo "No encuentro el archivo fasta: $GENOME_FASTA"
```

```
        exit 1
    fi
fi

# una vez está hecho el índice hacemos el alineamiento

echo ">>> Iniciando Alineamiento con HISAT2"
mkdir -p "$OUTPUT_DIR"

touch $ERR_FILE && touch $OUT_FILE #crear los archivos para guardar la
información

for FILE_R1 in ${INPUT_DIR}/*1_clean.fastq.gz
do
    # Comprobación de seguridad: si no hay archivos, el bucle intenta ejecutar
    el asterisco literal
    [ -e "$FILE_R1" ] || continue

    # Sacamos el nombre base del archivo (ej. Muestra_1_clean.fastq.gz)
    FILENAME=$(basename "$FILE_R1")

    # Esta línea elimina todo lo que vaya desde "_1_clean" o "_R1_clean" hasta
    el final.
    # El % indica "borrar desde el final la coincidencia más corta"
    SAMPLE_NAME=${FILENAME%_*1_clean.fastq.gz}

    # Sustituimos "1_clean" por "2_clean"
    FILE_R2="${FILE_R1/1_clean/2_clean}"

    # Archivos de salida. También hacemos un resumen (summary)
    OUTPUT_BAM="${OUTPUT_DIR}/${SAMPLE_NAME}_sorted.bam"
    SUMMARY_FILE="${OUTPUT_DIR}/${SAMPLE_NAME}_summary.txt"

    echo "-----"
    echo ">>> Procesando: $SAMPLE_NAME"
```

```
echo "      R1: $FILE_R1"
echo "      R2: $FILE_R2"

echo $SAMPLE_NAME>>>$ERR_FILE #esto imprime el nombre de la libreria en el
archivo error

# --dta: prepara para transcriptomas
# --summary-file: guarda stats
# -F 0x4: elimina lo que no mapea

hisat2 -p $CPUS --dta -x $INDEX_PREFIX \
      -1 "$FILE_R1" -2 "$FILE_R2" \
      --summary-file "$SUMMARY_FILE" 2>>>$ERR_FILE | \
samtools view -F 0x4 -b - | \
samtools sort -@ 2 -m 1G -o "$OUTPUT_BAM" -

echo ">>> Completado. Bam guardado en: $OUTPUT_BAM"

done

echo "-----"
echo "Terminado"

mamba deactivate
```

A.9. HISAT2 single ends

```
#!/bin/bash

eval "$(mamba shell hook --shell bash)"
mamba activate tfm_papaya

CPUS=8

INPUT_DIR="../../03_trimmed_data_fastp/PRJNA565901"
OUTPUT_DIR="../../05_alignment/PRJNA565901"
```

```
GENOME_FASTA="../../07_genome/GWHBFSC000000000.genome.fasta"
INDEX_DIR="../../07_genome/index_hisat2"
INDEX_PREFIX="${INDEX_DIR}/papaya_ref"

ERR_FILE="$OUTPUT_DIR/hisat2.err"
OUT_FILE="$OUTPUT_DIR/hisat2.out"

mkdir -p "$INDEX_DIR"

if [ -f "${INDEX_PREFIX}.1.ht2" ]; then
    echo "El índice ya existe en $INDEX_DIR."
    echo ">>> Saltando paso de construcción para ahorrar tiempo."
else
    echo ">>> El índice no existe. Construyendo ahora..."
    echo ">>> Genoma entrada: $GENOME_FASTA"

    if [ -f "$GENOME_FASTA" ]; then
        hisat2-build -p $CPUS $GENOME_FASTA $INDEX_PREFIX
        echo "Índice construido con éxito"
    else
        echo "No encuentro el archivo fasta: $GENOME_FASTA"
        exit 1
    fi
fi

echo ">>> Iniciando Alineamiento con HISAT2"
mkdir -p "$OUTPUT_DIR"

touch $ERR_FILE && touch $OUT_FILE #crear los archivos para guardar la
información

for FILE in ${INPUT_DIR}/*_clean.fastq.gz
do
```



```
[ -e "$FILE" ] || continue

FILENAME=$(basename "$FILE")

SAMPLE_NAME=${FILENAME/_clean.fastq.gz}

OUTPUT_BAM="${OUTPUT_DIR}/${SAMPLE_NAME}_sorted.bam"
SUMMARY_FILE="${OUTPUT_DIR}/${SAMPLE_NAME}_summary.txt"

echo "-----"
echo "Procesando: $SAMPLE_NAME"
echo "    Input: $FILE"
echo $SAMPLE_NAME>>>$ERR_FILE #esto imprime el nombre de la libreria en el
archivo error

# he cambiado el -1 y -2 por -U para lecturas single end

hisat2 -p $CPUS --dta -x $INDEX_PREFIX \
    -U "$FILE" \
    --summary-file "$SUMMARY_FILE" 2>>$ERR_FILE | \
samtools view -F 0x4 -b - | \
samtools sort -@ 2 -m 1G -o "$OUTPUT_BAM" -

echo ">>> Completado. Bam guardado en: $OUTPUT_BAM"
done

echo "-----"
echo "Terminado"

mamba deactivate
```

A.10. *featureCounts Paired Ends*

```
#!/bin/bash
```

```
# Inicialización del entorno
eval "$(mamba shell hook --shell bash)"
mamba activate tfm_papaya

# --- CONFIGURACIÓN ---
CPUS=8
INPUT_DIR="../../05_alignment/PRJNA591254"
OUTPUT_DIR="../../06_quantification/PRJNA591254"

# Tu archivo original (GFF)
GFF_FILE="../../07_genome/GWHBFSC000000000.gff"

# El archivo NUEVO que vamos a crear (GTF)
GTF_FILE="../../07_genome/papaya_standard.gtf"

OUTPUT_FILE="${OUTPUT_DIR}/matriz_conteos_papaya.txt"

mkdir -p "$OUTPUT_DIR"

# --- PASO 1: CONVERSIÓN DE FORMATO ---
echo ">>> Paso 1: Convirtiendo GFF a GTF estándar..."

if [ ! -f "$GTF_FILE" ]; then
    # gffread convierte el formato y limpia la estructura
    # -T: Fuerza salida GTF
    # -o: Archivo de salida
    gffread "$GFF_FILE" -T -o "$GTF_FILE"
    echo ">>> Conversión completada: $GTF_FILE"
else
    echo ">>> El archivo GTF ya existe, saltando conversión."
fi

# --- PASO 2: CUANTIFICACIÓN ---
```

```
echo ">>> Paso 2: Iniciando Cuantificación..."

count_bams=$(ls -1 "${INPUT_DIR}"/*.bam 2>/dev/null | wc -l)

if [ "$count_bams" != "0" ]; then
    echo ">>> Encontrados $count_bams BAMs."

    # AHORA USAMOS PARÁMETROS ESTÁNDAR
    # Como hemos convertido el archivo, ya tiene 'gene_id' y formato correcto.
    # Quitamos -F GFF y -g Parent porque ya es un GTF normal.

    featureCounts -T $CPUS -p --countReadPairs \
        -a "$GTF_FILE" \
        -t exon \
        -g gene_id \
        -o "$OUTPUT_FILE" \
        "${INPUT_DIR}"/*.bam

    echo ">>> Conteo finalizado."
    echo ">>> Matriz guardada en: $OUTPUT_FILE"

else
    echo "!!! ERROR: No hay archivos BAM en $INPUT_DIR"
fi
```

A.11. *featureCounts* Single Ends

```
#!/bin/bash

# Inicialización del entorno
eval "$(mamba shell hook --shell bash)"
mamba activate tfm_papaya

# --- CONFIGURACIÓN ---
CPUS=8
INPUT_DIR="../../05_alignment/PRJNA565901"
```

```
OUTPUT_DIR="../../06_quantification/PRJNA565901"

# Tu archivo original (GFF)
GFF_FILE="../../07_genome/GWHBFSC000000000.gff"

# El archivo NUEVO que vamos a crear (GTF)
GTF_FILE="../../07_genome/papaya_standard.gtf"

OUTPUT_FILE="${OUTPUT_DIR}/matriz_conteos_papaya.txt"

mkdir -p "$OUTPUT_DIR"

# --- PASO 1: CONVERSIÓN DE FORMATO ---
echo ">>> Paso 1: Convirtiendo GFF a GTF estándar..."

if [ ! -f "$GTF_FILE" ]; then
    # gffread convierte el formato y limpia la estructura
    # -T: Fuerza salida GTF
    # -o: Archivo de salida
    gffread "$GFF_FILE" -T -o "$GTF_FILE"
    echo ">>> Conversión completada: $GTF_FILE"
else
    echo ">>> El archivo GTF ya existe, saltando conversión."
fi

# --- PASO 2: CUANTIFICACIÓN ---
echo ">>> Paso 2: Iniciando Cuantificación..."

count_bams=$(ls -1 "${INPUT_DIR}"/*.bam 2>/dev/null | wc -l)

if [ "$count_bams" != "0" ]; then
    echo ">>> Encontrados $count_bams BAMs."

    # AHORA USAMOS PARÁMETROS ESTÁNDAR
```

```
# Como hemos convertido el archivo, ya tiene 'gene_id' y formato correcto.
# Quitamos -F GFF y -g Parent porque ya es un GTF normal.

featureCounts -T $CPUS \
  -a "$GTF_FILE" \
  -t exon \
  -g gene_id \
  -o "$OUTPUT_FILE" \
  "${INPUT_DIR}"/*.bam

echo ">>> Conteo finalizado."
echo ">>> Matriz guardada en: $OUTPUT_FILE"

else
  echo "!!! ERROR: No hay archivos BAM en $INPUT_DIR"
fi
```

A.12. Script de columnas y longitud

```
#!/bin/bash

#Quitamos la cabecera de gene_counts_FC1, y nos quedamos con las columnas 1 y
6 (longitud).

sed '1d' matriz_conteos_papaya.txt | cut -f 1,6 > gene_length.tsv

#Hacemos lo mismo pero para obtener los conteos (columnas 1, y de la 7 al
final).

sed '1d' matriz_conteos_papaya.txt | cut -f 1,7- > gene_counts_columns.tsv
#Aplicamos el script de R.
```

A.13. Script to TPM

```
library(edgeR)
library(DGEobj.utils)
```

```
setwd("C:/Users/alexp/OneDrive/Escritorio/Máster
Bioinformática/TFM/Datasets/Matrices/PRJNA591254")

#Cargamos archivos
counts <- read.table(file = "gene_counts_columns.tsv",
                     sep = "\t",
                     header = TRUE,
                     row.names = 1)
counts <- as.matrix(counts)

gene_length <- read.table(file = "gene_length.tsv",
                          sep = "\t",
                          header = TRUE,
                          row.names = 1)
gene_length <- as.matrix(gene_length)

#Calculamos los TPMs
TPMs <- convertCounts(countsMatrix = counts,
                      unit = "TPM",
                      geneLength = gene_length,
                      log = FALSE,
                      normalize = "none",
                      prior.count = NULL)

#Quitamos el número de réplica de las columnas
cols <- colnames(TPMs)
cols <- gsub('\\_\\d$', '', cols)
colnames(TPMs) <- cols

#Guardamos los TPMs
write.table(round(TPMs, digits = 2), #Guardamos 2 decimales
            file = "08 Carica papaya immune response induced by CTS-N after
inoculating PLDMV ini.txt",
            quote = FALSE,
            sep = "\t",
```

```
row.names = TRUE,  
col.names = NA)
```

A.14. Formateo de nombres

```
library(edgeR)  
library(DGEobj.utils)  
  
setwd("C:/Users/alexp/OneDrive/Escritorio/Máster  
Bioinformática/TFM/Datasets/Matrices/PRJNA880626")  
  
# 1. Cargamos archivos  
counts <- as.matrix(read.table("gene_counts_columns.tsv", sep = "\t", header =  
TRUE, row.names = 1))  
gene_length <- as.matrix(read.table("gene_length.tsv", sep = "\t", header =  
TRUE, row.names = 1))  
  
# 2. Calculamos los TPMs  
TPMs <- convertCounts(countsMatrix = counts,  
                        unit = "TPM",  
                        geneLength = gene_length,  
                        log = FALSE,  
                        normalize = "none")  
  
# 3. Limpieza de nombres originales (quedarnos solo con el SRR)  
colnames(TPMs) <- sub(".*(SRR[0-9]+).*", "\\1", colnames(TPMs))  
  
# 4. Diccionario de nombres nuevos  
nuevos_nombres <- c(  
  "SRR21590098" = "1B unripe stage",  
  "SRR21590100" = "1B unripe stage",  
  "SRR21590102" = "1B unripe stage",  
  "SRR21590104" = "1B ripe stage",  
  "SRR21590106" = "1B ripe stage",  
  "SRR21590108" = "1B ripe stage",  
  "SRR21590110" = "RB1 unripe stage",  
  "SRR21590112" = "RB1 unripe stage",  
  "SRR21590114" = "RB1 unripe stage",  
  "SRR21590116" = "RB1 ripe stage",  
  "SRR21590118" = "RB1 ripe stage",  
  "SRR21590120" = "RB1 ripe stage"  
)  
  
# 5. Aplicar el cambio de nombre  
nombres_actualizados <- nuevos_nombres[colnames(TPMs)]  
colnames(TPMs) <- ifelse(is.na(nombres_actualizados), colnames(TPMs),  
nombres_actualizados)
```

```
# -----  
# 6. REORDENAR LAS COLUMNAS (¡Lo que faltaba!)  
# -----  
orden_grupos <- c( "1B ripe stage", "1B unripe stage", "RB1 ripe stage", "RB1  
unripe stage")  
  
# Buscamos las posiciones exactas de las columnas en el orden deseado  
indices_ordenados <- unlist(lapply(orden_grupos, function(grupo) {  
  # which() nos da las posiciones exactas donde el nombre es idéntico al grupo  
  which(colnames(TPMs) == grupo)  
}))  
  
# Reordenamos la matriz usando esos índices  
TPMs_ordenado <- TPMs[, indices_ordenados, drop = FALSE]  
  
# -----  
# 7. Guardar el archivo FINAL  
# -----  
# Redondeamos a 2 decimales y guardamos (sin sufijos .1", .2" porque es una  
matriz)  
write.table(round(TPMs_ordenado, digits = 2),  
            file =  
"02_C._papaya_fruit_ripening_of_two_varieties_with_different_flavor_profile.tx  
t",  
            sep = "\t",  
            quote = FALSE,  
            col.names = NA)  
  
print("¡Proceso completado! TPMs calculados, renombrados, ordenados y  
guardados con éxito.")
```

A.15. Diamond Non-redundant

```
#!/usr/bin/env bash  
#SBATCH -J diamondNR  
#SBATCH --ntasks=1  
#SBATCH --cpus-per-task=128  
#SBATCH --mem=520gb  
#SBATCH --time=7-00:00:00  
#SBATCH --constraint=cal  
#SBATCH --error=diamondNR.%J.err  
#SBATCH --output=diamondNR.%J.out  
  
module purge  
module load diamond/2.1.24  
  
query="../../05_annotation/papaya/SunUp/PapayaGenomic.protein.fasta"  
  
# ☒ Ruta corregida a la base de datos NR
```



```
nr_db="/mnt/home/soft/squeezemeta/programs/x86_64/squeezemetaDB_4oct23/db/nr.d
mnd"

# ☒ Crear carpeta de salida si no existe
mkdir -p ../06_results_diamond/papaya/SunUp

output="../06_results_diamond/papaya/SunUp/$(basename "${query}/.fasta/}")"

echo "$query"

diamond blastp \
  --db "$nr_db" \
  --query "$query" \
  -o "${output}_diamond_NR.tsv" \
  --outfmt 6 qseqid sseqid bitscore stitle \
  -p "$SLURM_CPUS_PER_TASK" \
  --ultra-sensitive \
  -b 20 -c 1 \
  --max-target-seqs 1

# Filter by bitscore > 45
awk -F"\t" '$3 >= 45 {print $1"\t"$2"\t"$4}' \
  "${output}_diamond_NR.tsv" > "${output}_diamond_NR_filtered.tsv"

# Remove identifier from description column
awk -F"\t" '{sub(/^[^ ]+ /, "", $3); print $1"\t"$2"\t"$3}' \
  "${output}_diamond_NR_filtered.tsv" >
  "${output}_diamond_NR_filtered_def.tsv"

rm "${output}_diamond_NR_filtered.tsv"
```

A.16. Diamond Araport11, SwissProt y TrEMBL

```
#!/usr/bin/env bash
#SBATCH -J diamond-annotation
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=128
#SBATCH --mem=520gb
#SBATCH --time=7-00:00:00
#SBATCH --constraint=cal
#SBATCH --error=diamondXML.%J.err
#SBATCH --output=diamondXML.%J.out

module purge
module load diamond/2.1.24

# Define files to analyse
query="../05_annotation/papaya/SunUp/PapayaGenomic.protein.fasta"
database=(" ../02_diamond_db/diamond_db/Athaliana_447_Araport11.protein.dmnd"
```

```
    "../02_diamond_db/diamond_db/uniprotkb_taxonomy_viridiplantae_AND_swissprot_2025_11_25.dmnd"
    "../02_diamond_db/diamond_db/uniprotkb_taxonomy_viridiplantae_AND_trembl_2025_11_25.dmnd")
description=(" ../02_diamond_db/diamond_db/araport11_desc.tsv"
    "../02_diamond_db/diamond_db/uniprotkb_taxonomy_viridiplantae_AND_swissprot_2025_11_25.tsv"
    "../02_diamond_db/diamond_db/uniprotkb_taxonomy_viridiplantae_AND_trembl_2025_11_25.tsv")

perl_script="/mnt/home/users/ihs_m_fruti_uma/alexph/fscratch/03_scripts/merge_2_lists.pl"

# ☒ -p para crear carpetas padre si no existen
mkdir -p ../06_results_diamond/papaya/SunUp
rm -f ../06_results_diamond/papaya/SunUp/diamond.err \
    ../06_results_diamond/papaya/SunUp/diamond.out
touch ../06_results_diamond/papaya/SunUp/diamond.err \
    ../06_results_diamond/papaya/SunUp/diamond.out

for i in "${!database[@]}"
do
    db="${database[$i]}"
    desc="${description[$i]}"
    out=$(basename "$db")
    out="${out/.dmnd/}"
    out="../06_results_diamond/papaya/SunUp/${out}"
    echo "$out"

    # Run diamond blastp
    diamond blastp \
        --db "$db" \
        --query "$query" \
        --threads "$SLURM_CPUS_PER_TASK" \
        --max-target-seqs 1 \
        --ultra-sensitive \
        --out "$out.tsv" \
        --header simple \
    2>> ../06_results_diamond/papaya/SunUp/diamond.err \
    1>> ../06_results_diamond/papaya/SunUp/diamond.out

    # Filter by bitscore > 45
    awk '$12 >= 45 {print $1"\t"$2}' "$out.tsv" > "${out}_filtered.tsv"

    # Edit if SwissProt
    if [[ "$db" == *"swissprot"* ]]; then
        sed -E 's/sp\|([^\|]+)\|([^\t\n]+)/\1/g' "${out}_filtered.tsv" \
            | sed -E 's/(\t[^\t]+)-[0-9]+\1/g' > "${out}_tmp.tsv"
        mv "${out}_tmp.tsv" "${out}_filtered.tsv"
    fi
done
```

```
fi

# Edit if TrEMBL
if [[ "$db" == *"trembl"* ]]; then
    sed -E 's/tr\|([^\|]+)\|([^\t\n]+)/\1/g' "${out}_filtered.tsv" \
    | sed -E 's/(\t[^\t]+)-[0-9]+)/\1/g' > "${out}_tmp.tsv"
    mv "${out}_tmp.tsv" "${out}_filtered.tsv"
fi

# Merge con descripción usando el script de Perl
perl "$perl_script" "${out}_filtered.tsv" "$desc" 2 1 \
    | cut -f 1,2,4 > "${out}_filtered_annotated.tsv"

done
```

A.17. Interproscan

```
#!/usr/bin/env bash
#SBATCH -J InterProScan
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=16
#SBATCH --mem=16gb
#SBATCH --time=7-00:00:00
#SBATCH --constraint=cal
#SBATCH --error=ipr.%J.err
#SBATCH --output=ipr.%J.out

module purge
module load interproscan/5.67-99.0

query="../05_annotation/papaya/SunUp/PapayaGenomic.protein.fasta"

mkdir -p ../06_results_diamond/papaya/SunUp

output="../06_results_diamond/papaya/SunUp/$(basename "${query/.fasta/}")"

echo "$query"

# Limpiar asteriscos antes de correr InterProScan
query_clean="${output}_no_asterisks.fasta"
sed 's/\*//g' "$query" > "$query_clean"

interproscan.sh \
    -appl Pfam,SUPERFAMILY,ProSiteProfiles \
    -t p \
    -iprlookup \
    -dp \
    -f TSV \
    -cpu "$SLURM_CPUS_PER_TASK" \
```

```
-i "$query_clean" \  
-o "${output}_results_ipr.tsv"
```

A.18. Reducción de la dimensionalidad en R

```
# =====  
# Reducción de dimensionalidad - Desarrollo de flor de papaya  
# Métodos: PCA · MDS · ICA · t-SNE · UMAP  
#  
# Condiciones: FS2, FS3, FS4 (femenina) / MS2, MS3, MS4 (masculina)  
# 3 réplicas por condición · 18 muestras · ~24 700 genes  
#  
# Paquetes necesarios (instalar si no están):  
#   install.packages(c("edgeR", "ggplot2", "ggrepel",  
#                       "fastICA", "Rtsne", "umap", "patchwork"))  
# =====  
  
library(edgeR)  
library(ggplot2)  
library(ggrepel)  
library(fastICA)  
library(Rtsne)  
library(umap)  
library(patchwork) # Combinar gráficos ggplot2  
  
# — Parámetros —————  
MIN_CPM <- 1  
MIN_LIB <- 3  
  
COLORES <- c(  
  FS2 = "#1EFC72",  
  FS3 = "#46BD73",  
  FS4 = "#4D7D60",  
  MS2 = "#FC1C0B",  
  MS3 = "#BD4037",  
  MS4 = "#7D4743"  
)  
  
FORMAS <- c(FS2 = 16, FS3 = 16, FS4 = 16,  
            MS2 = 17, MS3 = 17, MS4 = 17)  
  
# — Carga de datos —————  
counts <- read.table(  
  file      = "03_C._papaya_pistil_development.txt",  
  sep       = "\t",  
  header    = TRUE,  
  row.names = 1  
)
```

```
# — Metadatos de muestras —————
condicion      <- gsub("\\.[0-9]+$", "", colnames(counts))
num_rep        <- ave(seq_along(condicion), condicion, FUN = seq_along)
etiquetas_rep  <- paste0(condicion, "_", num_rep)

cat(sprintf("Muestras: %d | Genes cargados: %d\n",
            ncol(counts), nrow(counts)))

# — Filtrado por CPM —————
cpms           <- cpm(counts)
keep           <- rowSums(cpms > MIN_CPM) >= MIN_LIB
counts_filt    <- counts[keep, ]
cat(sprintf("Genes tras filtrado (CPM > %g en >= %d muestras): %d\n\n",
            MIN_CPM, MIN_LIB, sum(keep)))

# — Normalización TMM —————
grupo         <- factor(condicion)
d             <- DGEList(counts = counts_filt, group = grupo)
d             <- calcNormFactors(d)
ncounts       <- cpm(d, normalized.lib.sizes = TRUE, log = TRUE)

# — Elementos gráficos compartidos —————
escala_color  <- scale_color_manual(values = COLORES, name = "Condición")
escala_forma  <- scale_shape_manual(values = FORMAS, name = "Condición")

# Tema para PNGs individuales (con leyenda)
tema_individual <- function(titulo) {
  list(
    labs(title = titulo),
    theme_bw(),
    theme(
      plot.title       = element_text(size = 12, face = "bold", hjust = 0.5),
      legend.position  = "bottom",
      legend.title     = element_text(size = 9),
      legend.text      = element_text(size = 8.5),
      axis.text        = element_text(size = 8),
      axis.title       = element_text(size = 9.5),
      panel.grid.major = element_blank(),
      panel.grid.minor = element_blank(),
      panel.background = element_blank()
    ),
    guides(
      color = guide_legend(ncol = 3, byrow = TRUE,
                          override.aes = list(size = 3.5)),
      shape = guide_legend(ncol = 3, byrow = TRUE,
                          override.aes = list(size = 3.5))
    )
  )
}
```

```
# Tema para paneles de la figura combinada (sin leyenda, más compacto)
tema_panel <- function(titulo) {
  list(
    labs(title = titulo),
    theme_bw(),
    theme(
      plot.title      = element_text(size = 17, face = "bold", hjust = 0.5),
      #legend.position = "none",
      axis.text       = element_text(size = 13),
      axis.title      = element_text(size = 17),
      panel.grid.major = element_blank(),
      panel.grid.minor = element_blank(),
      panel.background = element_blank()
    )
  )
}

# Construye el gráfico base reutilizable (sin tema ni escalas)
construir_base <- function(df, x, y, nombre_eje_x, nombre_eje_y) {
  ggplot(df, aes(x = .data[[x]], y = .data[[y]])) +
    geom_point(aes(color = condicion, shape = condicion),
              size = 2.5, alpha = 0.9) +
    geom_text_repel(
      aes(label = muestra, color = condicion),
      size = 4.5,
      segment.size = 0.3,
      segment.color = "grey50",
      max.overlaps = 30,
      min.segment.length = 0,
      show.legend = FALSE
    ) +
    escala_color + escala_forma +
    labs(x = nombre_eje_x, y = nombre_eje_y)
}

# Guarda la versión individual (con leyenda)
guardar_individual <- function(gg_base, titulo, nombre_archivo) {
  gg <- gg_base + tema_individual(titulo)
  ggsave(nombre_archivo, plot = gg, width = 7, height = 7, dpi = 300)
  cat(sprintf("Guardado: %s\n", nombre_archivo))
}

# =====
# 1. PCA
# =====
pca <- prcomp(t(ncounts), scale. = FALSE)
var_exp <- pca$sdev^2 / sum(pca$sdev^2)
```

```
cat("— PCA: varianza explicada —————\n")
for (i in 1:min(6, length(var_exp))) {
  cat(sprintf(" PC%d: %.1f%%\n", i, var_exp[i] * 100))
}
cat("\n")

pca_df      <- as.data.frame(pca$x[, 1:2])
pca_df$condicion <- condicion
pca_df$muestra  <- etiquetas_rep

gg_pca_base <- construir_base(
  df      = pca_df,
  x       = "PC1", y = "PC2",
  nombre_eje_x = paste0("PC1 (", round(var_exp[1] * 100, 1), "%)"),
  nombre_eje_y = paste0("PC2 (", round(var_exp[2] * 100, 1), "%)")
)

guardar_individual(gg_pca_base,
  titulo      = "PCA - Desarrollo de flor de papaya",
  nombre_archivo = "pca_plot.png")

pca_out      <- as.data.frame(pca$x)
pca_out$muestra  <- etiquetas_rep
pca_out$condicion <- condicion
write.csv(pca_out, "pca_results.csv", row.names = FALSE)
cat("Guardado: pca_results.csv\n\n")

# =====
# 2. MDS
# =====
dist_mat      <- dist(t(ncounts), method = "euclidean")
mds           <- cmdscale(dist_mat, k = 2, eig = TRUE)
eig_pos       <- mds$eig[mds$eig > 0]
var_mds       <- eig_pos / sum(eig_pos)

mds_df        <- as.data.frame(mds$points)
colnames(mds_df) <- c("MDS1", "MDS2")
mds_df$condicion <- condicion
mds_df$muestra  <- etiquetas_rep

gg_mds_base <- construir_base(
  df      = mds_df,
  x       = "MDS1", y = "MDS2",
  nombre_eje_x = paste0("MDS1 (", round(var_mds[1] * 100, 1), "%)"),
  nombre_eje_y = paste0("MDS2 (", round(var_mds[2] * 100, 1), "%)")
)

guardar_individual(gg_mds_base,
  titulo      = "MDS - Desarrollo de flor de papaya",
```

```
nombre_archivo = "mds_plot.png")

write.csv(mds_df, "mds_results.csv", row.names = FALSE)
cat("Guardado: mds_results.csv\n\n")

# =====
# 3. ICA (entrada: primeras 10 PCs para evitar cuellos de botella)
# =====
set.seed(42)
n_pcs_ica <- min(10, ncol(pca$x))
ica <- fastICA(pca$x[, 1:n_pcs_ica], n.comp = 2, method = "C")

ica_df <- as.data.frame(ica$S)
colnames(ica_df) <- c("IC1", "IC2")
ica_df$condicion <- condicion
ica_df$muestra <- etiquetas_rep

gg_ica_base <- construir_base(
  df = ica_df,
  x = "IC1", y = "IC2",
  nombre_eje_x = "Componente Independiente 1",
  nombre_eje_y = "Componente Independiente 2"
)

guardar_individual(gg_ica_base,
  titulo = "ICA - Desarrollo de flor de papaya",
  nombre_archivo = "ica_plot.png")

write.csv(ica_df, "ica_results.csv", row.names = FALSE)
cat("Guardado: ica_results.csv\n\n")

# =====
# 4. t-SNE
# =====
set.seed(42)
perplexity_tsne <- min(5, floor((ncol(ncounts) - 1) / 3))

tsne <- Rtsne(
  X = pca$x[, 1:min(10, ncol(pca$x))],
  dims = 2,
  perplexity = perplexity_tsne,
  max_iter = 2000,
  pca = FALSE,
  verbose = FALSE
)

tsne_df <- as.data.frame(tsne$Y)
colnames(tsne_df) <- c("tSNE1", "tSNE2")
tsne_df$condicion <- condicion
```



```
tsne_df$muestra <- etiquetas_rep

cat(sprintf("— t-SNE: perplexity usada = %d —————\n\n",
           perplexity_tsne))

gg_tsne_base <- construir_base(
  df      = tsne_df,
  x       = "tSNE1", y = "tSNE2",
  nombre_eje_x = "t-SNE 1",
  nombre_eje_y = "t-SNE 2"
)

guardar_individual(gg_tsne_base,
                  titulo = paste0("t-SNE (perplexity=", perplexity_tsne,
                                ") - Desarrollo de flor de papaya"),
                  nombre_archivo = "tsne_plot.png")

write.csv(tsne_df, "tsne_results.csv", row.names = FALSE)
cat("Guardado: tsne_results.csv\n\n")

# =====
# 5. UMAP
# =====

set.seed(42)
umap_config <- umap.defaults
umap_config$n_neighbors <- min(5, ncol(ncounts) - 1)
umap_config$min_dist <- 0.3

umap_res <- umap(t(ncounts), config = umap_config)
umap_df <- as.data.frame(umap_res$layout)
colnames(umap_df) <- c("UMAP1", "UMAP2")
umap_df$condicion <- condicion
umap_df$muestra <- etiquetas_rep

gg_umap_base <- construir_base(
  df      = umap_df,
  x       = "UMAP1", y = "UMAP2",
  nombre_eje_x = "UMAP 1",
  nombre_eje_y = "UMAP 2"
)

guardar_individual(gg_umap_base,
                  titulo = "UMAP - Desarrollo de flor de papaya",
                  nombre_archivo = "umap_plot.png")

write.csv(umap_df, "umap_results.csv", row.names = FALSE)
cat("Guardado: umap_results.csv\n\n")

# =====
```

```
# FIGURA COMBINADA (patchwork)
#
# Layout: 3 columnas × 2 filas + leyenda común al pie
#
# [ A · PCA ] [ B · MDS ] [ C · ICA ]
# [ D · t-SNE ] [ E · UMAP ] [          ]
# [ LEYENDA ]
# =====

gg_pca_panel <- gg_pca_base + tema_panel("A · PCA")
gg_mds_panel <- gg_mds_base + tema_panel("B · MDS")
gg_ica_panel <- gg_ica_base + tema_panel("C · ICA")
gg_tsne_panel <- gg_tsne_base + tema_panel("D · t-SNE")
gg_umap_panel <- gg_umap_base + tema_panel("E · UMAP")

figura_combinada <- (
  # guide_area() ocupa el hueco vacío (fila 3, col 2) y recibe la leyenda
  wrap_plots(gg_pca_panel, gg_mds_panel, gg_ica_panel,
             gg_tsne_panel, gg_umap_panel, guide_area(),
             ncol = 2)
) +
plot_layout(guides = "collect") & # Leyendas idénticas → una sola
theme(
  legend.title = element_text(size = 21, face = "bold"),
  legend.text = element_text(size = 17),
  legend.key.size = unit(1.7, "cm")
) &
guides(
  color = guide_legend(ncol = 1, byrow = TRUE,
                      override.aes = list(size = 9)),
  shape = guide_legend(ncol = 1, byrow = TRUE,
                      override.aes = list(size = 9))
)

ggsave("figura_combinada.png",
       plot = figura_combinada,
       width = 15,
       height = 17,
       dpi = 300)

cat("Guardado: figura_combinada.png\n\n")
cat("== Análisis completado =====\n")
cat("PNG individuales : pca · mds · ica · tsne · umap\n")
cat("CSV individuales : pca · mds · ica · tsne · umap\n")
cat("Figura combinada : figura_combinada.png\n")
```

ANEXO B. Material complementario

El material complementario consta del siguiente contenido:

- Informes MultiQC de las lecturas brutas y procesadas.
- Tabla de metadatos de los diferentes conjuntos de datos.
- Archivos con los TPM de las muestras analizadas.
- Tablas de porcentaje de lecturas alineadas

Este queda disponible para su consulta a través del siguiente enlace:

<https://drive.proton.me/urls/JRKFGNRYKC#Vkq7oEcuzT2n>